



**BRAIN
SCAN**

BrainScan – System wspomagający analizę badań
obrazowych TK głowy

www.brainscan.ai



GastroView
endoskopia kapsułkowa



www.cta.ai/pl/publikacje/04



współpraca z światowym
koncernem medycznym
Medtronic



BrainScan
analiza badań obrazowych
TK mózgu



www.brainscan.ai

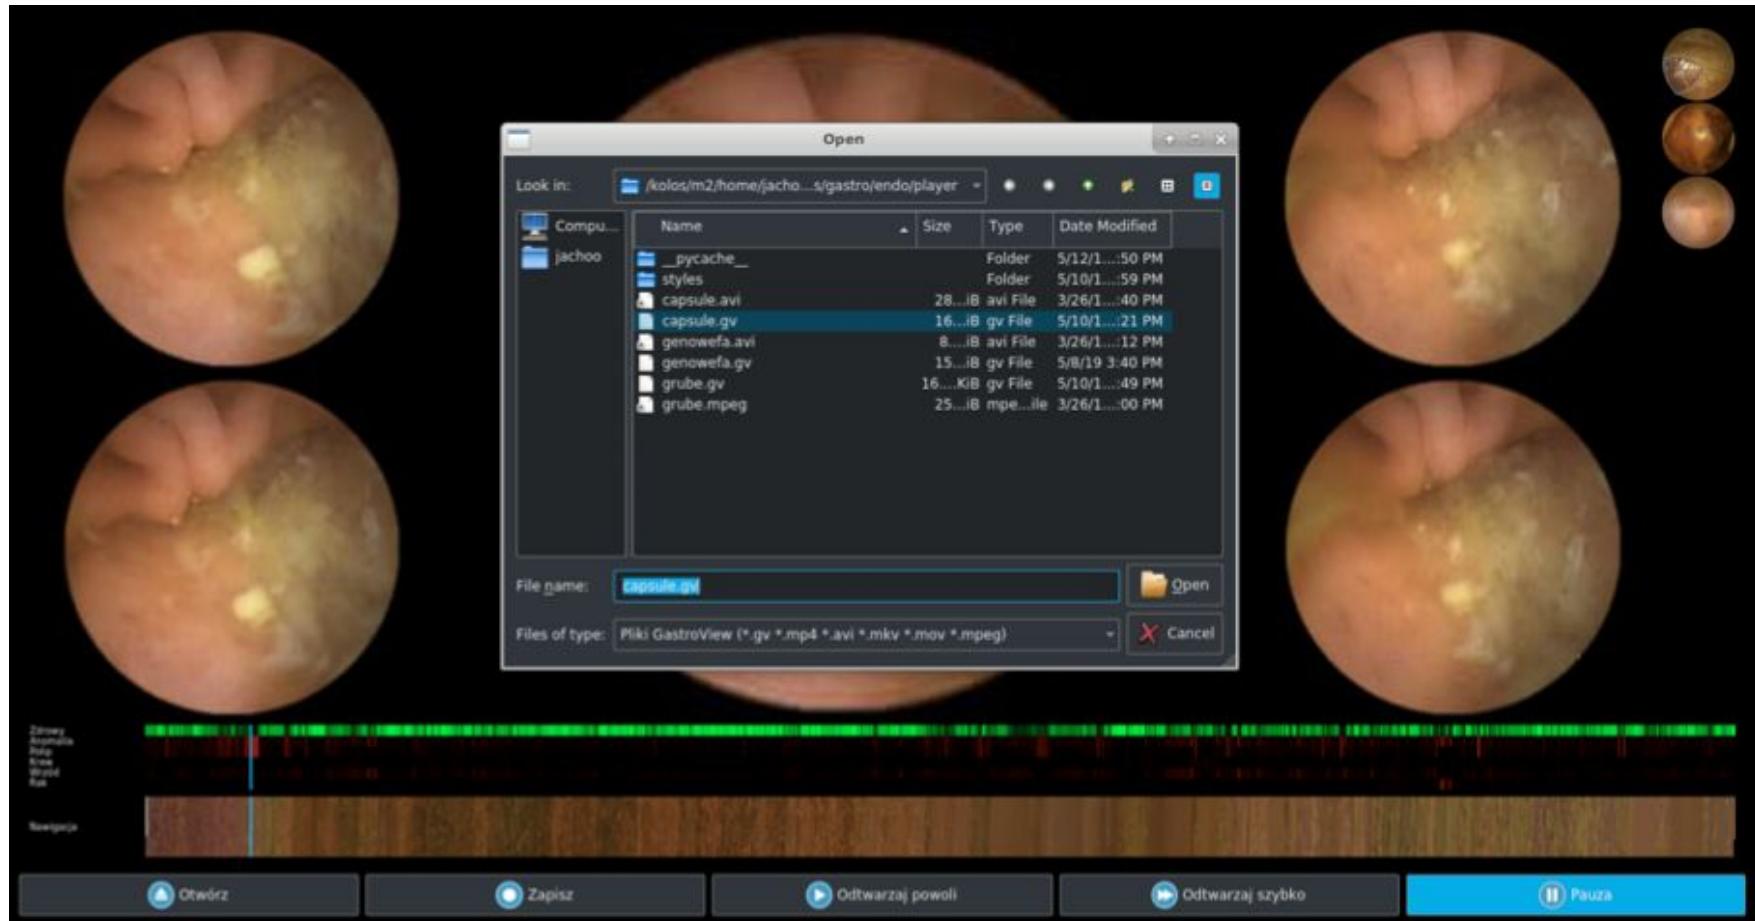


AIFactory
analiza obrazów w
przemyśle



www.ai-factory.pl

GastroView - endoskopia kapsułkowa



www.cta.ai/pl/publikacje/04



www.ai-factory.pl

GastroView
endoskopia kapsułkowa



www.cta.ai/pl/publikacje/04

BrainScan
analiza badań obrazowych TK
mózgu



www.brainscan.ai

AIFactory
analiza obrazów w
przemyśle



www.ai-factory.pl



Obecnie: około 1000 badań
obrazowych łącznie

Do dzisiaj projekt jest zawieszony,
między innymi ze względu na za
mały zbiór danych.



Obecnie: około 10K badań
obrazowych łącznie

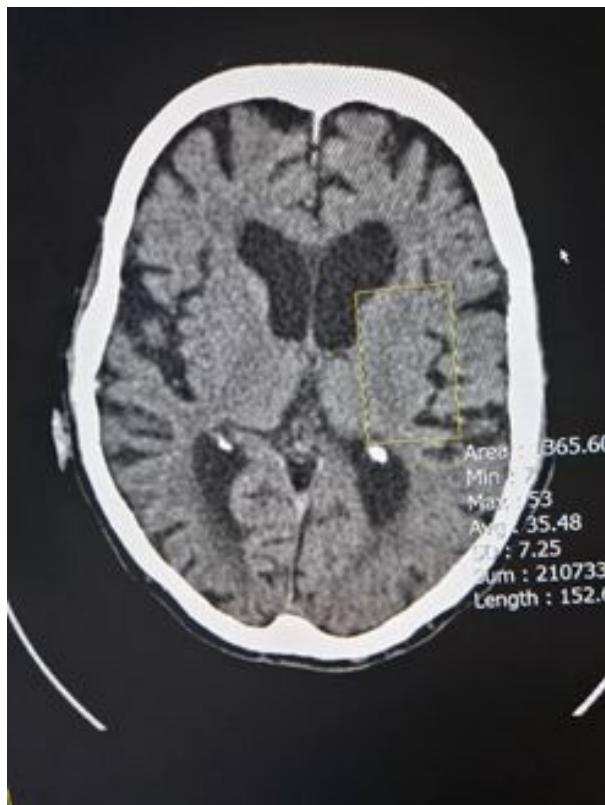
Do końca 2019: około 40K badań
obrazowych łącznie

Do końca 2020: około 100K badań
obrazowych łącznie

Obecnie: około 1000 zdjęć pudełek
leków na półkach

Krwawienie wewnętrzczaszkowe

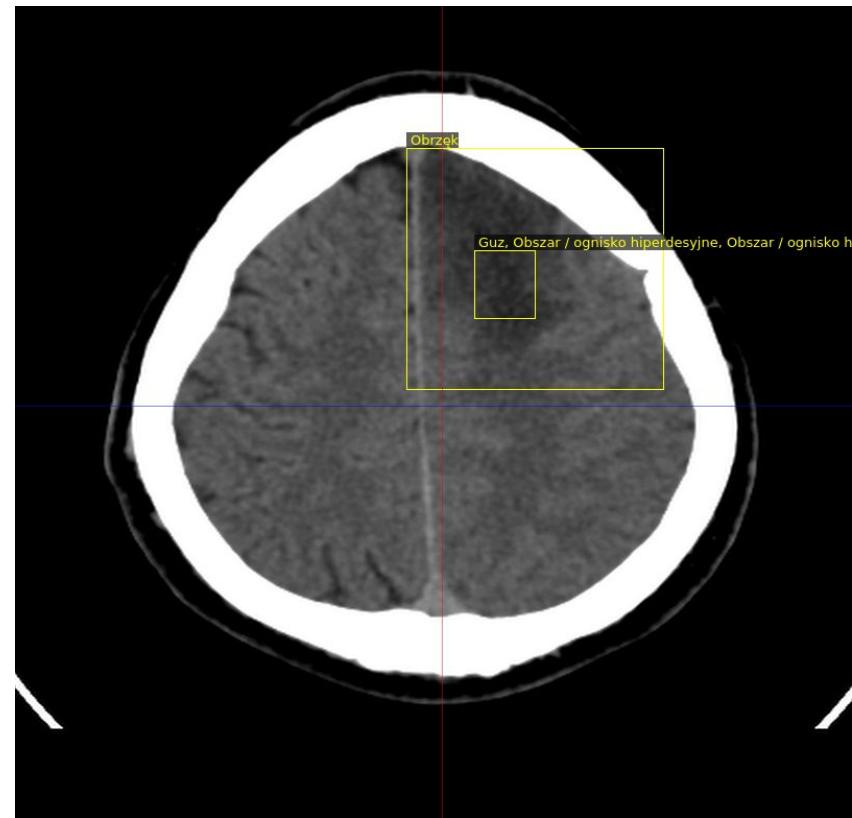
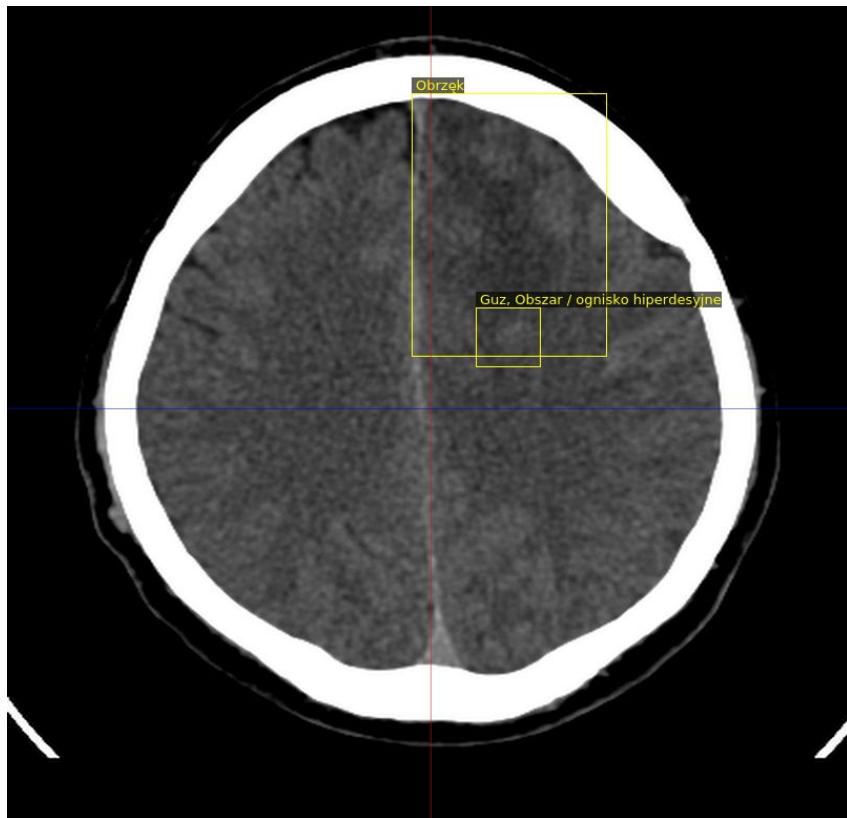
Ogniska udarowe i poudarowe



Przykład przedstawia przypadek pacjenta, u którego wystąpił ostry udar niedokrwienny. Zmiana udarowa w pierwszym dniu hospitalizacji, przedstawiona po lewej stronie, jest niezwykle subtelna, przez co z dużym prawdopodobieństwem może zostać przeoczona przez radiologa, co z kolei skutkuje brakiem wdrożenia odpowiedniego leczenia. Po prawej stronie przedstawiono natomiast obraz uzyskany w drugim dniu hospitalizacji, gdzie uszkodzenie tkanki mózgowej uległo znaczнемu powiększeniu i stało się wyraźnie widoczne, jednak wdrożenie skutecznego leczenia na tym etapie nie jest już niestety możliwe.

Guzy



Guzy

Mohammad R. Arbabsirani, Brandon K. Fornwalt, Gino J. Mongelluzzo, Jonathan D. Suever, Brandon D. Geise, Aalpen A. Patel & Gregory J. Moore

Advanced machine learning in action: identification of intracranial hemorrhage on computed tomography scans of the head with clinical workflow integration

ICH detection ROC AUC = 0.846

“During implementation, 94 of 347 routine studies were re-prioritized to stat, and 60/94 had ICH identified by the radiologist. Five new cases of ICH were identified, and median time to diagnosis was significantly reduced ($p < 0.0001$) from 512 to 19 min.”

npj | Digital Medicine

www.nature.com/npjdigitalmed

ARTICLE OPEN

Advanced machine learning in action: identification of intracranial hemorrhage on computed tomography scans of the head with clinical workflow integration

Mohammad R. Arbabsirani¹, Brandon K. Fornwalt^{1,2}, Gino J. Mongelluzzo¹, Jonathan D. Suever^{1,2}, Brandon D. Geise¹, Aalpen A. Patel^{1,2} and Gregory J. Moore¹

Intracranial hemorrhage (ICH) requires prompt diagnosis to optimize patient outcomes. We hypothesized that machine learning algorithms could automatically analyze computed tomography (CT) of the head, prioritize radiology worklists and reduce time to diagnosis of ICH. 46,583 head CTs (~2 million images) acquired from 2007–2017 were collected from several facilities across Geisinger. A deep convolutional neural network was trained on 37,074 studies and subsequently evaluated on 9499 unseen studies. The predictive model was implemented prospectively for 3 months to re-prioritize “routine” head CT studies as “stat” on real-time radiology worklists if an ICH was detected. Time to diagnosis was compared between the re-prioritized “stat” and “routine” studies. A neuroradiologist blinded to the study reviewed false positive studies to determine whether the dictating radiologist overlooked ICH. The model achieved an area under the ROC curve of 0.846 (0.837–0.856). During implementation, 94 of 347 “routine” studies were re-prioritized to “stat”, and 60/94 had ICH identified by the radiologist. Five new cases of ICH were identified, and median time to diagnosis was significantly reduced ($p < 0.0001$) from 512 to 19 min. In particular, one outpatient with vague symptoms on anti-coagulation was found to have an ICH which was treated promptly with reversal of anti-coagulation, resulting in a good clinical outcome. Of the 34 false positives, the blinded over-reader identified four probable ICH cases overlooked in original interpretation. In conclusion, an artificial intelligence algorithm can prioritize radiology worklists to reduce time to diagnosis of new outpatient ICH by 96% and may also identify subtle ICH overlooked by radiologists. This demonstrates the positive impact of advanced machine learning in radiology workflow optimization.

npj Digital Medicine (2018) 1:9; doi:10.1038/s41746-017-0015-z

INTRODUCTION

Intracranial hemorrhage (ICH) is a critical condition accounting for about 2 million strokes worldwide.¹ Hemorrhages can occur both within the brain parenchyma (intra-axial) or within the cranial vault but external to the brain parenchyma (extra-axial). Both intra-axial and extra-axial hemorrhage have significant clinical burden. For example, intra-axial hemorrhage affects approximately 40,000 to 67,000 patients per year in the United States^{2,3} with a 30-day mortality rate of 47 percent.⁴ Moreover, 46% of survivors of subarachnoid hemorrhage (a type of extra-axial hemorrhage) endure permanent cognitive impairment.^{5,6} Hospital admissions of ICH have dramatically increased in the past decade, probably due to increased life expectancy and lower blood pressure control.^{7,8} Importantly, early diagnosis of ICH is of critical clinical importance since nearly half of the resulting mortality occurs in the first 24 h⁹ and earlier treatment likely improves outcomes.¹⁰ Computed tomography (CT) of the head is the most widely used tool for diagnosing acute ICH, and the timing of diagnosis, therefore, depends on how quickly a head CT is both completed and subsequently interpreted by a clinician.

The interpretation time of radiological studies is highly dependent on the priority assigned to the exam by the ordering physician (for example “stat” vs. “routine”) and by patient status (inpatient vs. outpatient). Stat studies are typically interpreted within an hour (at our institution) while routine outpatient studies can take much longer based on the available radiology workforce. Therefore, detection of ICH in routine studies (especially those imaged in an outpatient setting) may be significantly delayed. ICH does occur in the outpatient setting, albeit with a lesser frequency than the inpatient or emergency department setting. For example, elderly outpatients on anticoagulation therapy experience higher risk of ICH. Importantly, initial symptoms may be vague, prompting a non-emergent, routine head CT.

Automated triage of imaging studies using computer algorithms has the potential to detect ICH earlier, ultimately leading to improved clinical outcomes. Such a quality improvement tool could be used to automatically manage the priority for interpretation of imaging studies with presumed ICH and help optimize radiology workflow. Machine learning and computer vision are among a suite of techniques for teaching computers to learn and detect patterns.

In particular, deep learning (a class of machine learning algorithms suitable for training large multi-layer neural networks) has been leveraged for a variety of automated classification tasks

¹Geisinger, Department of Radiology, 100 N. Academy Avenue, Danville, PA 17822-2007, USA and ²Geisinger, Department of Imaging Science and Innovation, 100 N. Academy Avenue, Danville, PA 17822-4400, USA

Correspondence: Aalpen A. Patel (aapatel@geisinger.edu)

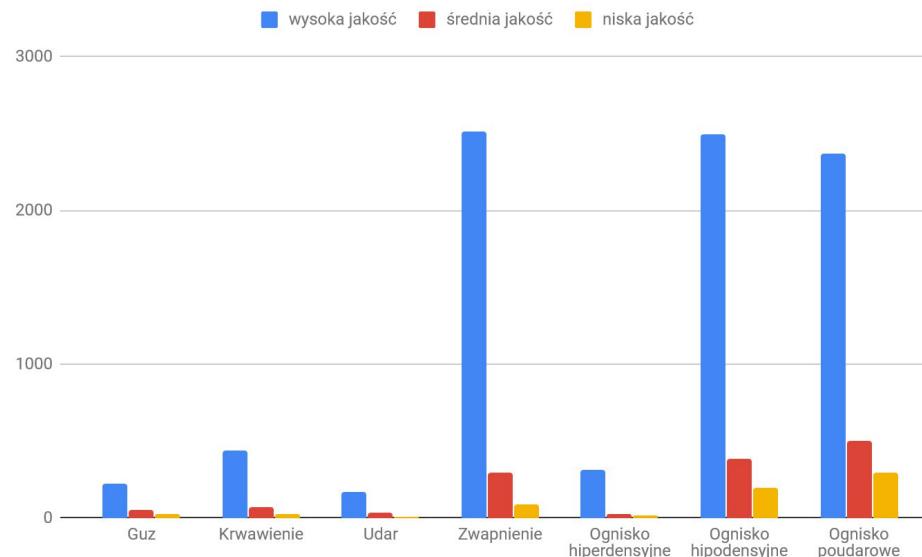
Mohammad R. Arbabsirani and Brandon K. Fornwalt contributed equally to this work.

Received: 18 September 2017 Revised: 7 December 2017 Accepted: 12 December 2017

Published online: 04 April 2018

Published in partnership with the Scripps Translational Science Institute

Statystyki zebranych danych



Ilość badań przypadających na detektowaną zmianę patologiczną				
	wysoka jakość	średnia jakość	niska jakość	wszystkie
Guz	221	56	30	307
Krwawienie	439	74	30	543
Udar	168	36	11	215
Zwapnienie	2511	300	93	2904
Ognisko hiperdensywne	314	30	14	358
Ognisko hipodensywne	2491	382	193	3066
Ognisko poudarowe	2366	505	300	3171
Razem	8510	1383	671	10564



Stan po przebytym ukrwotoczeniu rozległego ogniska udarowego lewej półkuli mózgu z efektem masy i wgłobieniem pod sierp. W badaniu obecnym utrzymuje się obrzęk lewej półkuli mózgu, z efektem masy i wgłobieniem pod sierp mózgu na ok 10 mm. Częściowa hemoliza ukrwotoczniego ogniska w płacie czołowym i ciemieniowym, z widoczną ścianą. og. wlk ok 82x36mm- wokół hypodensyjny obrzęk istoty białej. W prawej półkuli mózgu ogniska malacji w strukturach głębokich oraz kilka (około 3) w płacie czołowym - przebyte. Podejrzenie świeżego ogniska niedokrwieniennego (?) na sklepistości -zakręt czołowy przedni-górny. Układ komorowy przemieszczony w prawo, uciśnięty i modelowany. Podnamiotowo bez wyraźnej patologii. W tętnicach podstawy mózgu drobne zwapnienia. Pneumatyzacja zatok i kości skroniowych obustronnie w normie.

**WYNIK:**

Porównano z badaniem z 06/07/2015r. Nieco szersza przestrzeń przymózgowa wokół LPM do 7mm. Obraz krwiaka przymózgowego wokół PPM i ognisk stłuczenia z elementami ukrwotoczenia obu płatów skroniowych przedstawia się podobnie jak w badaniu poprzednim. Grubość krwiaka przymózgowego do ok. 8 mm. Cechy niewielkiego obrzęku w PPM- jak poprzednio. Mniejsza ilość powietrza w jamie czaszki- obecnie widoczny pojedynczy pęcherzyk gazu na sklepistości. Obraz zatok jak poprzednio. Szczelina złamania w k skroniowej, klinowej, jarzmowej prawej oraz obraz kości pokrywy czaszki - jak w bad. Poprzednim. Wn: nieco szersza do 7 mm przestrzeń płynowa wokół LPM, poza tym obraz mózgowia przedstawia się podobnie jak w badaniu z 6.07.2015r.



BRAIN
SCAN

BrainScan Tagger - narzędzie do opisywania i oznaczania obrazów

The image shows an axial CT scan of a brain. A yellow rectangular box highlights a hyperdense lesion in the left basal ganglia area. A context menu is open over this lesion, displaying the following options: 'Guz, Ognisko hiperdensywne' (Hyperdense lesion, Focus), 'Usuń' (Delete), 'Edytuj pozycję' (Edit position), and 'Edytuj nazwę' (Edit name).

Opis

U podstawy czaszki po stronie lewej zewnątrzmoźgowo między skrzydlem większym kości klinowej a szczytem piramidy widoczna słabo hiperdensyjna okrągła zmiana śr ok 16mm - może odpowiadać dużemu tętniakowi lub oponiakowi - wskazany MR z kontrastem i programem naczyniowym

Poza tym mózgiem bez zmian ogniskowych

Cech świeżego niedokrwienia nie stwierdza się

Nie stwierdza się obecności krawienia wśród, ani namozgowego

Układ komorowy symetryczny, nieposzerzony

Torbiel przegrody przeszroczystej szer do 5mm

Przestrzenie podpajęczynówkowe prawidłowe

Serie

Obrazów: 124

Obrazów: 124

Obrazów: 31

MPR

C: 50 W: 75

Nieprawidłowe badanie
 Brak rozpatrywanych zmian
 Niepoprawny opis

→ Następny

Resetuj okno Ukryj oznaczenia Usuń oznaczenia

data\tau_02042_082146\head_579_4, Badanie: 18/100 Adam Brzeski



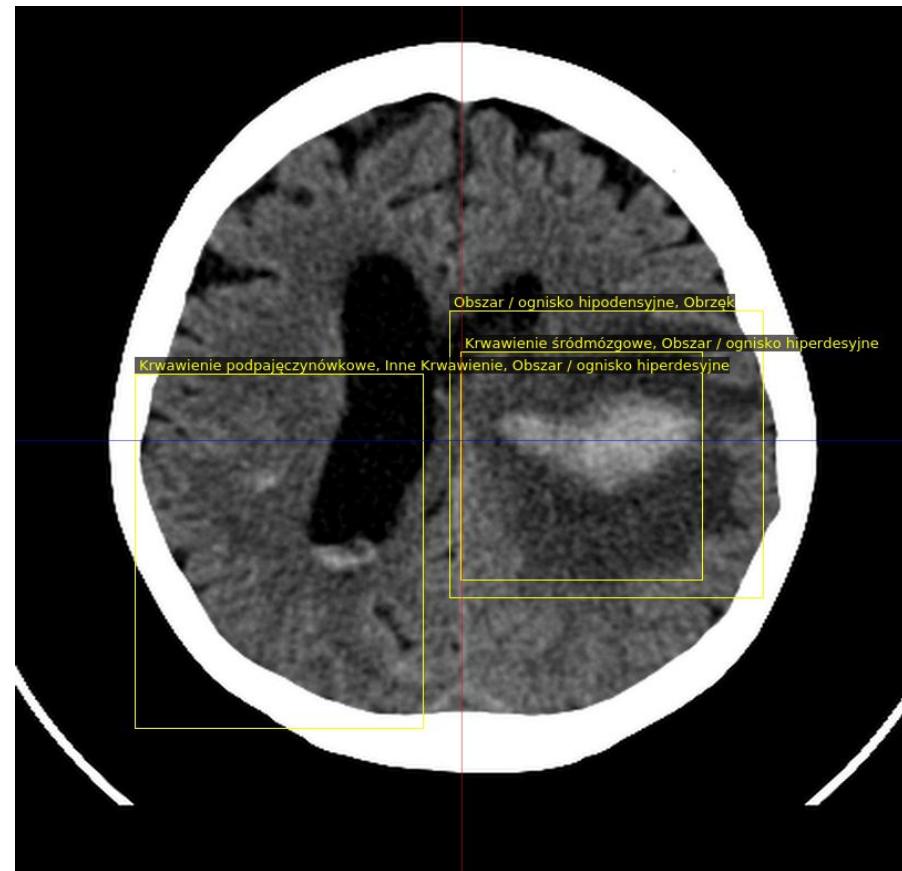
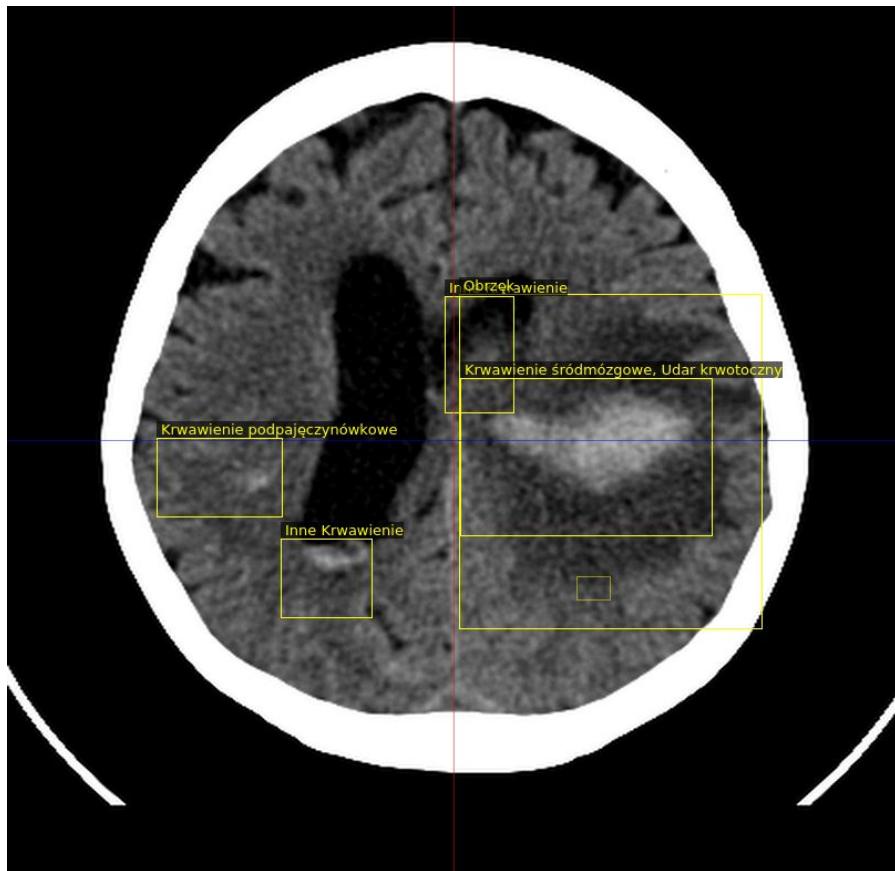
BRAIN
SCAN

BrainScan Tagger - narzędzie do opisywania i oznaczania obrazów

The grid of screenshots illustrates the BrainScan Tagger software interface and its features:

1. Main interface showing a brain scan with various regions of interest (ROIs) outlined in orange.
2. A detailed view of a specific ROI labeled "Lateral ventricle" with a callout to the "Region of Interest" panel.
3. A screenshot of the "Region of Interest" panel showing a list of ROIs and their properties.
4. A screenshot of the "Region of Interest" panel with a callout to the "Edit" button.
5. A screenshot of the "Edit" dialog for a selected ROI, showing fields for "Name", "Color", "Type", and "Volume".
6. A screenshot of the "Edit" dialog with a callout to the "OK" button.
7. A screenshot of the main interface showing multiple ROIs and a callout to the "Region of Interest" panel.
8. A screenshot of the main interface with a callout to the "Region of Interest" panel.
9. A screenshot of the "Region of Interest" panel with a callout to the "Delete" button.
10. A screenshot of the main interface showing a brain scan with ROIs and a callout to the "Region of Interest" panel.
11. A screenshot of the main interface with a callout to the "Region of Interest" panel.
12. A screenshot of the main interface with a callout to the "Region of Interest" panel.
13. A screenshot of the main interface showing a brain scan with ROIs and a callout to the "Region of Interest" panel.
14. A screenshot of the main interface with a callout to the "Region of Interest" panel.
15. A screenshot of the main interface showing a brain scan with ROIs and a callout to the "Region of Interest" panel.
16. A screenshot of the main interface with a callout to the "Region of Interest" panel.
17. A screenshot of the main interface showing a brain scan with ROIs and a callout to the "Region of Interest" panel.
18. A screenshot of the main interface with a callout to the "Region of Interest" panel.
19. A screenshot of the main interface showing a brain scan with ROIs and a callout to the "Region of Interest" panel.
20. A screenshot of the main interface with a callout to the "Region of Interest" panel.
21. A screenshot of the main interface showing a brain scan with ROIs and a callout to the "Region of Interest" panel.
22. A screenshot of the main interface with a callout to the "Region of Interest" panel.
23. A screenshot of the main interface showing a brain scan with ROIs and a callout to the "Region of Interest" panel.
24. A screenshot of the main interface with a callout to the "Region of Interest" panel.

Przykładowe oznaczenia lekarzy



Klasyfikacja badań obrazowych z TK głowy

Przykładowe oznaczenia lekarzy

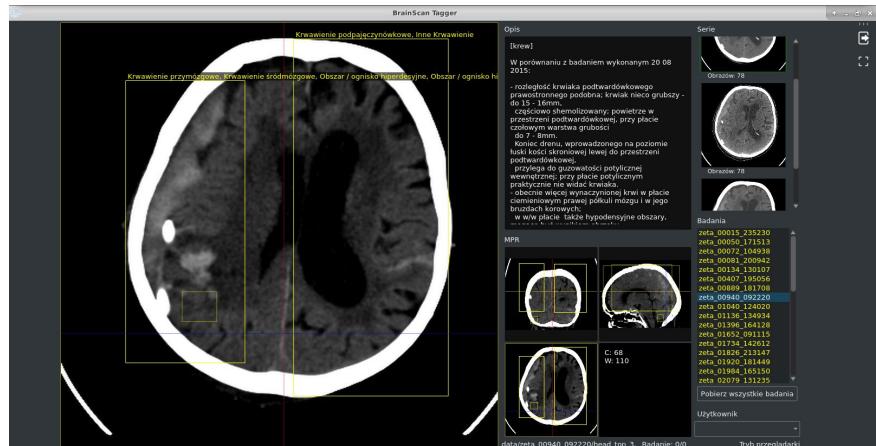
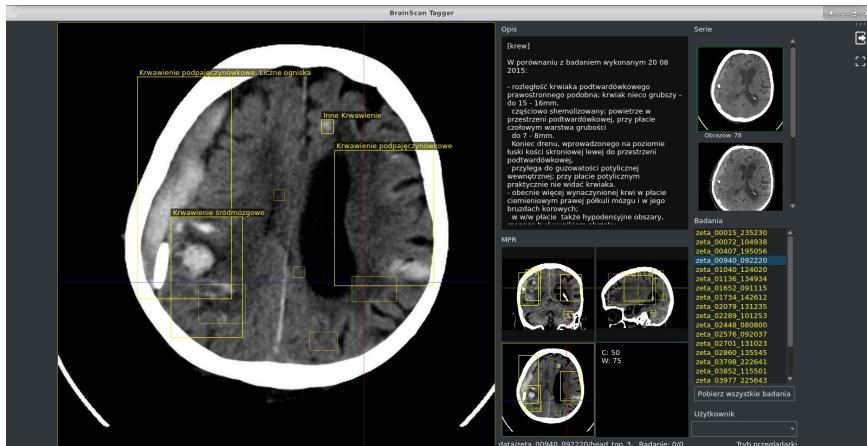
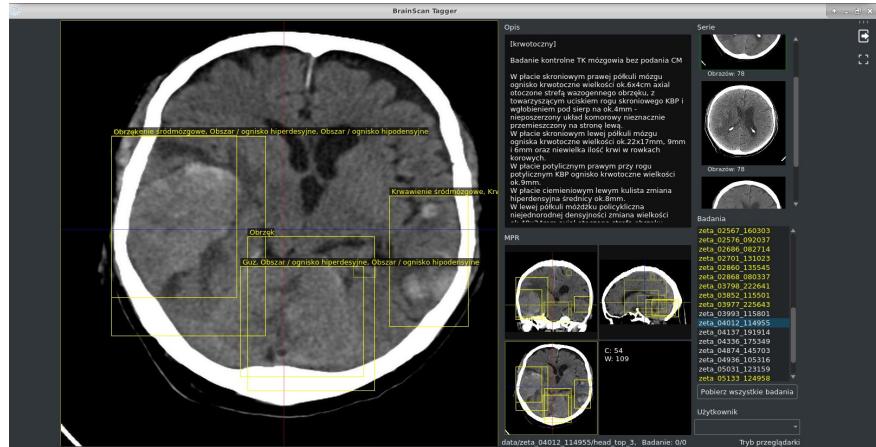
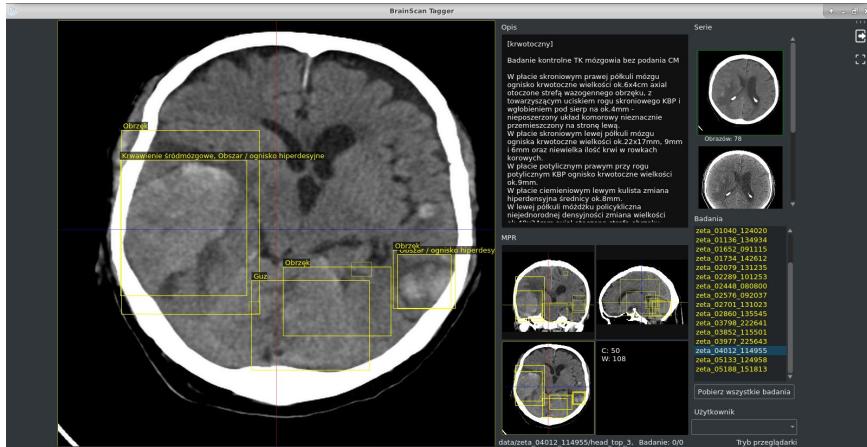


Table 3. Label assignment agreement (ignoring box localization)

Green = highest value in column, red = lowest, N = count of positive labels

Pathology	5 observers			4 observers			2 observers		
	N	ICC	Kappa	N	ICC	Kappa	N	ICC	Kappa
Tumor	197	0.46	0.41	166	0.43	0.38	101	0.54	0.52
Meninges	173	0.54	0.44	171	0.70	0.70	91	0.61	0.59
Calcification	161	0.36	0.28	160	0.47	0.44	83	0.53	0.53
Cyst	22	0.08	0.05	22	0.11	0.09	19	0.18	0.18
Vascular	52	0.25	0.22	48	0.34	0.36	15	0.52	0.52
Hemorrhage	345	0.80	0.79	292	0.86	0.86	144	0.87	0.87
EDH/SDH	124	0.72	0.72	101	0.73	0.73	55	0.69	0.69
SAH	68	0.56	0.53	63	0.64	0.63	39	0.75	0.74
ICH	174	0.66	0.65	152	0.70	0.69	74	0.63	0.61
IVH	55	0.75	0.71	50	0.86	0.86	26	0.92	0.92
Bleeding	42	0.16	0.17	37	0.16	0.18	20	0.17	0.17
Edema	192	0.43	0.38	188	0.54	0.54	106	0.45	0.44
Shift	112	0.58	0.49	110	0.75	0.75	57	0.74	0.74
Contusion	52	0.25	0.21	51	0.32	0.31	29	0.52	0.52
Ischemic	590	0.45	0.39	535	0.52	0.48	312	0.63	0.62
Acute stroke	299	0.66	0.65	256	0.70	0.70	135	0.77	0.77
Chronic stroke	162	0.20	0.15	162	0.26	0.25	102	0.53	0.53
Leukoaraiosis	203	0.34	0.25	203	0.46	0.42	145	0.53	0.50
Malacia	329	0.40	0.35	312	0.45	0.44	146	0.42	0.39

Pathology	PW vs JK	PW vs MP	JK vs MP
Charakter zmiany niemożliwy do określenia / obraz niejasny, wymaga weryfikacji	0.81	0.74	0.79
Guz	0.82	0.92	0.82
Inne krwawienie	0.92	0.96	0.92
Jama	0.84	0.94	0.82
Krwawienie	0.94	0.97	0.93
Krwiak nadtwardówkowy	1.0	1.0	1.0
Krwiak podtwardówkowy	0.89	0.89	0.97
Krwiak przymózgowy	0.92	0.93	0.94
Krwotok podpajęczynówkowy	0.95	0.94	0.94
Krwotok w układzie komorowym	0.99	0.99	0.99
Krwotok śródmożgowy	0.88	0.93	0.91
Krwotok śródmożgowy (bez przebicia do komór)	0.99	1.0	0.99
Krwotok śródmożgowy z przebiciem do komór	1.0	1.0	1.0
Leukoarajoza	0.76	0.84	0.66
Malacia	0.65	0.83	0.74
Obrzęk	0.79	0.92	0.8
Obszar / ognisko hiperdesyjne	0.84	0.42	0.41
Obszar / ognisko hipodensyjne	0.92	0.57	0.53
Obszar / ognisko izodensyjne	0.87	0.93	0.86
Obszar stłuczenia	0.93	0.93	0.95
Obszar zawiera artefakty	0.9	0.86	0.88
Obszar zawiera liczne ogniska	0.7	0.66	0.71
Przemieszczenie struktur śródmożgowych	0.93	0.97	0.93
Torbiel	0.93	0.94	0.97
Udar niedokrwienny dokonany	0.83	0.76	0.72
Udar niedokrwienny świeży	0.9	0.89	0.87
Zmiana naczyniopochodna	0.89	0.8	0.79
Zmiana naczyniowa	0.96	0.97	0.95
Zmiana oponowa	0.85	0.93	0.87
Zmiana wymaga różnicowania	0.68	0.67	0.68
Zmiana związana z wiekiem	0.66	0.97	0.68
Zwapnienie	0.85	0.86	0.83

Konkurencja - firma Qure AI

	AUC (95% CI)	High sensitivity operating point		High specificity operating point	
		Sensitivity (95% CI)	Specificity (95% CI)	Sensitivity (95% CI)	Specificity (95% CI)
Qure25k dataset					
Intracranial haemorrhage	0.9194 (0.9119-0.9269)	0.9006 (0.8882-0.9121)	0.7295 (0.7230-0.7358)	0.8349 (0.8197-0.8492)	0.9004 (0.8960-0.9047)
Intra-parenchymal	0.8977 (0.8884-0.9069)	0.9031 (0.8894-0.9157)	0.6046 (0.5976-0.6115)	0.7670 (0.7479-0.7853)	0.9046 (0.9003-0.9087)
Intraventricular	0.9559 (0.9424-0.9694)	0.9358 (0.9085-0.9569)	0.8343 (0.8291-0.8393)	0.9220 (0.8927-0.9454)	0.9267 (0.9231-0.9302)
Subdural	0.9161 (0.9001-0.9321)	0.9152 (0.8888-0.9370)	0.6542 (0.6476-0.6607)	0.7960 (0.7600-0.8288)	0.9041 (0.9000-0.9081)
Extradural	0.9288 (0.9083-0.9494)	0.9034 (0.8635-0.9349)	0.7936 (0.7880-0.7991)	0.8207 (0.7716-0.8631)	0.9068 (0.9027-0.9107)
Subarachnoid	0.9044 (0.8882-0.9205)	0.9100 (0.8844-0.9315)	0.6678 (0.6613-0.6742)	0.7758 (0.7406-0.8083)	0.9012 (0.8971-0.9053)
Calvarial fracture	0.9244 (0.9130-0.9359)	0.9002 (0.8798-0.9181)	0.7749 (0.7691-0.7807)	0.8115 (0.7857-0.8354)	0.9020 (0.8978-0.9061)
Midline shift	0.9276 (0.9139-0.9413)	0.9114 (0.8872-0.9319)	0.8373 (0.8322-0.8424)	0.8754 (0.8479-0.8995)	0.9006 (0.8964-0.9047)
Mass effect	0.8583 (0.8462-0.8703)	0.8622 (0.8439-0.8792)	0.6157 (0.6089-0.6226)	0.7086 (0.6851-0.7314)	0.9068 (0.9026-0.9108)
CQ500 dataset					
Intracranial haemorrhage	0.9419 (0.9187-0.9651)	0.9463 (0.9060-0.9729)	0.7098 (0.6535-0.7617)	0.8195 (0.7599-0.8696)	0.9021 (0.8616-0.9340)
Intra-parenchymal	0.9544 (0.9293-0.9795)	0.9478 (0.8953-0.9787)	0.8123 (0.7679-0.8515)	0.8433 (0.7705-0.9003)	0.9076 (0.8726-0.9355)
Intraventricular	0.9310 (0.8654-0.9965)	0.9286 (0.7650-0.9912)	0.6652 (0.6202-0.7081)	0.8929 (0.7177-0.9773)	0.9028 (0.8721-0.9282)
Subdural	0.9521 (0.9117-0.9925)	0.9434 (0.8434-0.9882)	0.7215 (0.6769-0.7630)	0.8868 (0.7697-0.9573)	0.9041 (0.8726-0.9300)
Extradural	0.9731 (0.9113-1.0000)	0.9231 (0.6397-0.9981)	0.8828 (0.8506-0.9103)	0.8462 (0.5455-0.9808)	0.9477 (0.9238-0.9659)
Subarachnoid	0.9574 (0.9214-0.9934)	0.9167 (0.8161-0.9724)	0.8654 (0.8295-0.8962)	0.8667 (0.7541-0.9406)	0.9049 (0.8732-0.9309)
Calvarial fracture	0.9624 (0.9204-1.0000)	0.9487 (0.8268-0.9937)	0.8606 (0.8252-0.8912)	0.8718 (0.7257-0.9570)	0.9027 (0.8715-0.9284)
Midline shift	0.9697 (0.9403-0.9991)	0.9385 (0.8499-0.9830)	0.8944 (0.8612-0.9219)	0.9077 (0.8098-0.9654)	0.9108 (0.8796-0.9361)
Mass effect	0.9216 (0.8883-0.9548)	0.9055 (0.8408-0.9502)	0.7335 (0.6849-0.7782)	0.8189 (0.7408-0.8816)	0.9038 (0.8688-0.9321)

Neither of the datasets was used during the training process. AUCs are shown for nine critical CT findings in both these datasets. Two operating points were chosen on the ROC curve for high sensitivity and high specificity, respectively. Absolute number used for calculation of sensitivity and specificity are in the appendix (p7). AUC=area under the receiver operating characteristic curve. ROC=receiver operating characteristic.

Table 4: Performance of the algorithms on the Qure25k and CQ500 datasets

ICH trained on 4304 manually segmented scans.

Mass effect trained on 320 scans with binary per-slice annotations.

Wyniki modeli klasyfikacji uzyskane w BrainScanie na własnym zbiorze testowym

Metric	Hemorrhage	Stroke
t_{val}	0.50	0.55
accuracy	0.88	0.85
sensitivity	0.60	0.69
specificity	0.90	0.74
precision	0.35	0.73
F1-score	0.44	0.70
F1-score-spec	0.72	0.64
AUC	0.83	0.81

Wyniki uzyskane zbiorze QC500 (opublikowanym przez Qure.AI) oraz na wydzielonej połowie tego zbioru (test subset)

Metric	Hemorrhage (CQ500)	CQ500 test subset
t_{val}	0.50	0.50
accuracy	0.71	0.64
sensitivity	0.45	0.68
specificity	0.90	0.71
F1-score	0.56	0.67
F1-score-spec	0.60	0.69
AUC	0.76	0.73

Wyniki uzyskane po dotrenowaniu modelu częścią danych ze zbioru QC500 (rozłączną z podzbiorem testowym) na własnym zbiorze testowym oraz na testowej połowie zbioru (test subset)

Metric	BrainScan test set	CQ500 test subset
t_{val}	0.02	0.02
accuracy	0.88	0.74
sensitivity	0.74	0.71
specificity	0.89	0.81
precision	0.33	0.75
F1-score	0.46	0.73
F1-score-spec	0.81	0.76
AUC	0.81	0.77

Klasyfikacja badań obrazowych z TK głowy

Wyniki testów systemu QureAI na 16 badaniach ze zbioru testowego BrainScana. Kolumny po lewej - QureAI, kolumny po prawej - BrainScan. Kolor zielony oznacza prawidłową odpowiedź, czerwony błędną. Poprawność klasyfikacji okazała się identyczna dla obu zbiorów.

Thumbnail	Report	QureAI response	BrainScan response ($t=0.50$)				
	W porównaniu z badaniem poprzednim z 30.12.2015 obraz mózgowy nie uleg zmianie - nadal widoczna niewielka ilość krwi w rowkach koronowych płyta clementiowej LPM. W płacie clementiowym PPM głębokością 2mm. W obrazie obecny jest przekształcony.	Intraparenchymal hemorrhage of 2.63 ml in left frontal, right parietal, right occipital regions. Subarachnoid hemorrhage. Midline shift. Mass effect.	Hemorrhage ($s=0.59$)		Badanie z r. 10.01.2016 r. W porównaniu z badaniem poprzednim zmiany nie uległy. Widoczny obraz mózgu z niewielkimi zmianami krwi w rowkach koronowych płyty clementiowej LPM. W płacie clementiowym głębokością 2mm. W obrazie obecny jest przekształcony.	Intraparenchymal hemorrhage of 2.63 ml in left frontal, right parietal, right occipital regions. Subarachnoid hemorrhage. Midline shift. Mass effect.	Hemorrhage ($s=0.57$)
	WYNIK: Podejrzenie zakażenia i infekcji zakaźnej. Niekontakcyjny przestrzenny zatyczkowy wólk UHM do 7mm. Obraz krwiaka przyzmęgowego wólk PPM i ogólna stężenie z elementami ukrwotoczniennia obu płyt clementiowych przedstawia się podobnie do obrazu z badania poprzedniego. Wysokość krwiaka przyzmęgowego do 8 a mm. Cechy niekotwicowe obrazu - PMS - jak poprzednio. Makroskopicznie żółtawo-brązowy, jasno czerwony obiekt wiedomny, pojedynczy gęsty przeszy gazu na sklepieniu.	Subdural Hemorrhage of 45.03 ml in bilateral frontal, right temporal regions. Subarachnoid hemorrhage. Fracture. Midline shift.	Hemorrhage ($s=0.86$)		Badanie z r. 10.01.2016 r. W porównaniu z badaniem poprzednim zmiany nie uległy. Widoczny obraz mózgu z niewielkimi zmianami krwi w rowkach koronowych płyty clementiowej LPM. W płacie clementiowym głębokością 2mm. W obrazie obecny jest przekształcony.	Subdural Hemorrhage of 45.03 ml in bilateral frontal, right temporal regions. Subarachnoid hemorrhage. Fracture. Midline shift.	Hemorrhage ($s=0.70$)
	W porównaniu z poprzednim badaniem TK z dnia 07-09-2014: - niewielkie zmniejszenie rozległego krwiaka przyzmęgowego otaczającego płytę clementiową, skromnowy i clementiowy PPM, obecne głębokością 2mm. - krwiak przyzmęgowy w płacie clementiowym LPM podobnych wymiarów - nadal widoczne krew przy krawędzi krwi, ilość nie ulega zmianie. - stężenie prawego płata clementiowego podobne wielkości, z kremowatożółtawym ogniskiem (obiekt z tendencją do zmiany się), z głębokością 2mm. - krwiak przyzmęgowy w płacie clementiowym LPM podobnych wymiarów - nadal widoczne krew przy krawędzi krwi, ilość nie ulega zmianie. - stężenie lewego płata clementiowego podobne wielkości, z głębokością 2mm.	Subdural Hemorrhage of 58.41 ml in right frontal, right temporal, right parietal regions. Intraparenchymal hemorrhage of 2.15 ml in bilateral frontal region. Subarachnoid hemorrhage. Fracture.	Hemorrhage ($s=0.80$)		Badanie z r. 10.01.2016 r. W porównaniu z badaniem poprzednim zmiany nie uległy. Widoczny obraz mózgu z niewielkimi zmianami krwi w rowkach koronowych płyty clementiowej LPM. W płacie clementiowym głębokością 2mm. W obrazie obecny jest przekształcony.	Subdural Hemorrhage of 58.41 ml in right frontal, right temporal, right parietal regions. Intraparenchymal hemorrhage of 2.15 ml in bilateral frontal region. Subarachnoid hemorrhage. Fracture.	Hemorrhage ($s=0.70$)
	W badaniu obecnym utrzumuje się obraz lewej płytki mózgu, z głębokością 2mm. W obrazie obecny jest przekształcony.	Subdural Hemorrhage of 1.21 ml in left frontal, left parietal regions. Intraparenchymal hemorrhage of 18.70 ml in left frontal, left parietal regions. Subarachnoid hemorrhage. Midline shift.	Hemorrhage ($s=0.84$)		Badanie z r. 10.01.2016 r. W porównaniu z badaniem poprzednim zmiany nie uległy. Widoczny obraz mózgu z niewielkimi zmianami krwi w rowkach koronowych płyty clementiowej LPM. W płacie clementiowym głębokością 2mm. W obrazie obecny jest przekształcony.	Subdural Hemorrhage of 1.21 ml in left frontal, left parietal regions. Intraparenchymal hemorrhage of 18.70 ml in left frontal, left parietal regions. Subarachnoid hemorrhage. Midline shift.	Normal ($s=0.17$)
	Krwawienia śródmięśniowe i przyzmęcowe nie stwardnione. Zobowiązująca obecność czerwonej substancji w sklepieniu głębokością 2mm nie stwardniona.	No hemorrhages or fractures detected.	Normal ($s=0.49$)		Badanie z r. 10.01.2016 r. W porównaniu z badaniem poprzednim zmiany nie uległy. Widoczny obraz mózgu z niewielkimi zmianami krwi w rowkach koronowych płyty clementiowej LPM. W płacie clementiowym głębokością 2mm. W obrazie obecny jest przekształcony.	No hemorrhages or fractures detected.	Normal ($s=0.06$)
	W obrazie widoczny krwiak przyzmęcowy w obu płytkach mózgu oraz czerwona substancja w sklepieniu głębokością 2mm.	No hemorrhages or fractures detected.	Normal ($s=0.45$)		Badanie z r. 10.01.2016 r. W porównaniu z badaniem poprzednim zmiany nie uległy. Widoczny obraz mózgu z niewielkimi zmianami krwi w rowkach koronowych płyty clementiowej LPM. W płacie clementiowym głębokością 2mm. W obrazie obecny jest przekształcony.	No hemorrhages or fractures detected.	Normal ($s=0.18$)
	W obrazie widoczny krwiak przyzmęcowy w obu płytkach mózgu oraz czerwona substancja w sklepieniu głębokością 2mm.	No hemorrhages or fractures detected.	Normal ($s=0.30$)		Badanie wykonane przed i po dobrym podaniu środka kontrastowego. Cechy głębokościowe nie stwardnia się.	No hemorrhages or fractures detected.	Normal ($s=0.21$)
	W obrazie widoczny krwiak przyzmęcowy w obu płytkach mózgu jako wynik nietarczniczej kręgów mózgowych. W strukturach głębokich głębokością 2mm. W obrazie widoczny krwiak przyzmęcowy w obiektach głębokością 2mm.	No hemorrhages or fractures detected.	Normal ($s=0.46$)		Badanie z r. 10.01.2016 r. W porównaniu z badaniem poprzednim zmiany nie uległy. Widoczny obraz mózgu z niewielkimi zmianami krwi w rowkach koronowych płyty clementiowej LPM. W płacie clementiowym głębokością 2mm. W obrazie obecny jest przekształcony.	No hemorrhages or fractures detected.	Normal ($s=0.18$)

Przetwarzanie obrazów 2D vs 3D

Mohammad R. Arbabsirani, Brandon K. Fornwalt,
 Gino J. Mongelluzzo, Jonathan D. Suever,
 Brandon D. Geise, Aalpen A. Patel & Gregory J. Moore

"Advanced machine learning in action: identification of intracranial hemorrhage on computed tomography scans of the head with clinical workflow integration"

npj | Digital Medicine

www.nature.com/npjdigitalmed/

ARTICLE OPEN

Advanced machine learning in action: identification of intracranial hemorrhage on computed tomography scans of the head with clinical workflow integration

Mohammad R. Arbabsirani¹, Brandon K. Fornwalt^{1,2}, Gino J. Mongelluzzo¹, Jonathan D. Suever^{1,2}, Brandon D. Geise¹, Aalpen A. Patel^{1,2} & Gregory J. Moore¹

Intracranial hemorrhage (ICH) requires prompt diagnosis to optimize patient outcomes. We hypothesized that machine learning algorithms could automatically prioritize computed tomography (CT) of the head, prioritize radiology workflow, and reduce time to diagnosis of ICH. A deep convolutional neural network was trained on 37/74 studies and subsequently evaluated on 949 unseen studies. The predictive model was implemented prospectively for 3 months to re-prioritize "routine" head CTs as "stat" on real-time radiology workflow. An ICH was identified in 11% of all head CTs. When we re-prioritized the "routine" stat head CTs, routine studies were more likely to have ICH. A receiver operating characteristic curve analysis demonstrated that the predicted radiologists overestimated ICH. The model achieved an area under the ROC curve of 0.846 (0.837–0.856). During implementation, 94 of 347 "routine" studies were re-prioritized to "stat", and 60% had ICH identified by the radiologist. Five new cases of ICH were identified, and median time to diagnosis was 10 min. In patients with ICH, there was no significant association between initial symptoms and anticoagulation or found to have an ICH which was often promptly ruled out with reversal of anticoagulants, resulting in a good clinical outcome. Of the 34 false positives, the blinded over-reader identified four probable ICH cases overlooked in original interpretation. In conclusion, this machine learning algorithm can prioritize radiology workflows to reduce time to diagnosis of new outpatient ICH by 90% and may also identify subtle ICH overlooked by radiologists. This demonstrates the positive impact of advanced machine learning in radiology workflow optimization.

npj Digital Medicine (2018) 5:19, doi:10.1038/npjd-017-0015-2

INTRACRANIAL HEMORRHAGE

Intracranial hemorrhage (ICH) is a critical condition accounting for about 2 out of every 10 strokes worldwide.¹ ICH can occur within the brain parenchyma (extra-axial) or within the ventricular vault but extends to the brain parenchyma (extra-axial). Both intra-axial and extra-axial hemorrhage have significant clinical burden. For example, extra-axial hemorrhage affects approximately 67,000 patients per year in the United States²—approximately with a 30-day mortality rate of 47 percent.³ Moreover, 46% of survivors of subarachnoid hemorrhage (a type of extra-axial hemorrhage) experience cognitive impairment.⁴ Hospital admissions of ICH have dramatically increased in the past decade probably due to increased life expectancy and poor blood pressure control.⁵ Although ICH is a leading cause of death, its clinical importance since nearly half of the resulting mortality occurs in the first 24 h and earlier treatment likely improves outcome.⁶ Computed tomography (CT) is the best test for rapidly ruled out tool for diagnosis of ICH, and the timing of diagnosis, therefore, depends on how quickly a head CT is both completed and subsequently read by a clinician.⁷

The interpretation time of radiological studies is highly dependent on the priority assigned to the exam by the ordering

physician (for example "stat" vs "routine") and by patient status (inpatient vs. outpatient). Stat studies are typically interpreted immediately (at our institution within 10 min), whereas outpatient studies can take much longer based on the availability of radiologists. Therefore, detection of ICH in routine studies (especially those imaged in an outpatient setting) may be significantly delayed. ICH in an outpatient setting often presents with a low suspicion, and the inpatient or emergency department. For example, elderly outpatients on anticoagulation therapy experience higher risk of ICH.⁸ Importantly, initial symptoms may be vague, and it may be necessary to repeat the CT.

Automatic triage of imaging studies using computer algorithms has the potential to detect ICH earlier, ultimately leading to improved patient outcomes. Such an automated triage tool could be used to automatically manage the priority for interpretation of imaging studies with presumed ICH. Help from radiologists, however, is still required. Machine learning and computer vision are among a suite of techniques for teaching computers to learn and detect patterns.

In particular, we learned a class of machine learning algorithms suitable for training large, multi-layer neural networks to detect patterns in medical images.

The interpretation time of radiological studies is highly dependent on the priority assigned to the exam by the ordering physician (for example "stat" vs "routine") and by patient status (inpatient vs. outpatient). Stat studies are typically interpreted immediately (at our institution within 10 min), whereas outpatient studies can take much longer based on the availability of radiologists. Therefore, detection of ICH in routine studies (especially those imaged in an outpatient setting) may be significantly delayed. ICH in an outpatient setting often presents with a low suspicion, and the inpatient or emergency department. For example, elderly outpatients on anticoagulation therapy experience higher risk of ICH.⁸ Importantly, initial symptoms may be vague, and it may be necessary to repeat the CT.

Automatic triage of imaging studies using computer algorithms has the potential to detect ICH earlier, ultimately leading to improved patient outcomes. Such an automated triage tool could be used to automatically manage the priority for interpretation of imaging studies with presumed ICH. Help from radiologists, however, is still required. Machine learning and computer vision are among a suite of techniques for teaching computers to learn and detect patterns.

In particular, we learned a class of machine learning algorithms suitable for training large, multi-layer neural networks to detect patterns in medical images.

The interpretation time of radiological studies is highly dependent on the priority assigned to the exam by the ordering

¹Geisinger Department of Radiology, 100 N. Academy Avenue, Danville, PA 17822-2007, USA and ²Geisinger, Department of Imaging Science and Innovation, 100 N. Academy Avenue, Danville, PA 17822-2007, USA

Correspondence: Aslyan A. Patel (aslyan@geisinger.edu)

Mohammad R. Arbabsirani, Brandon K. Fornwalt contributed equally to this work.

Received: 18 September 2017; Revised: 7 December 2017; Accepted: 12 December 2017

Published online: 4 April 2018

Published in partnership with the Scripps Translational Science Institute

npj nature partner journal

Diego Ardila, Atilla P. Kiraly, Sujeeth Bharadwaj, Bokyung Choi, Joshua J. Reicher, Lily Peng, Daniel Tse, Moziyar Etemadi, Wenxing Ye, Greg Corrado, David P. Naidich & Shravya Shetty

"End-to-end lung cancer screening with three-dimensional deep learning on low-dose chest computed tomography"

**nature
medicine**

LETTERS

<https://doi.org/10.1038/4159-019-0447-x>

End-to-end lung cancer screening with three-dimensional deep learning on low-dose chest computed tomography

Diego Ardila^{1,5}, Atilla P. Kiraly^{1,5}, Sujeeth Bharadwaj^{1,5}, Bokyung Choi^{1,5}, Joshua J. Reicher², Lily Peng³, Daniel Tse^{3,4*}, Moziyar Etemadi^{3,4}, Wenxing Ye⁴, Greg Corrado⁴, David P. Naidich⁴ and Shravya Shetty¹

With an estimated 160,000 deaths in 2018, lung cancer is the most common cause of cancer death in the United States.¹ Lung cancer screening has been shown to reduce mortality by 20–43% and is now included in US screening guidelines.² Existing challenges include the high cost of screening and the high rates of false-positive results.^{3–5} We propose a deep learning algorithm that uses a patient's current and prior computed tomography (CT) scans to predict the risk of lung cancer. Our model is a state-of-the-art deep learning algorithm that outperforms the curve on 6,716 National Lung Cancer Screening Trial cases, and performs similarly on an independent clinical validation set of 17,111 cases. Because the majority of lung cancer cases are diagnosed via computed tomography imaging was not available, our model outperformed all six radiologists with absolute reductions of 11% in false positives and 5% in false negatives. Where prior computed tomography imaging was available, performance was on-par with the same radiologists. This creates an opportunity to optimize the screening process via computer vision. Although only 10% of the lung cancer cases in our patients remain unscreened, we show the potential for deep learning models to increase the accuracy, consistency and adoption of lung cancer screening worldwide.

In the United States, Preventive Task Force recently recommended low-dose computed tomography (LDCT) lung cancer screening in high-risk populations based on reported improved mortality rates.⁶ In 2014, the American College of Radiology published the Lung-RADS guidelines for LDCT lung cancer screening, to standardize image interpretation by radiologists and improve diagnostic performance.⁷ Lung-RADS is based on a variety of imaging findings, but primarily size, density and growth.⁸ At screening sites, Lung-RADS and other models such as PanCan are used to determine which lesions require further investigation for clinical management.^{9,10} Improving the sensitivity and specificity of lung cancer screening is imperative because of the high cost and potential for mild disease to be diagnosed and managed. Any bias in procedures resulting from false negatives and false positives^{11–13}. Despite improved consistency, persistent inter-grade variability and incomplete characterization of comprehensive imaging findings remains as limitations of Lung-RADS. These

limitations suggest opportunities for more sophisticated systems to improve performance and inter-reader consistency.¹⁴ Deep learning approaches offer the potential to automatically perform complex image analysis, detect subtle holistic imaging findings and unify methodologies for improved evaluation.¹⁵ Computer vision tools have been approved by the Food and Drug Administration (FDA) with the goal of addressing workflow efficiency and performance through augmented detection of lung nodules on low-dose computed tomography (CT).¹⁶ Our approach has generated promising results for either nodule detection or diagnostic support for lesions manually selected by imaging experts^{17–20}. Nodule detection systems were engineered with the goal of improving the sensitivity and specificity of nodules while minimizing costs to specificity, thereby falling into the category of computer-aided detection (CADe)²¹. This approach highlights small nodules, leaving malignancy risk evaluation and characterization to radiologists. Diagnostic support for lesions pre-identified by radiologists and their associated performance was-on par with the same radiologists. This creates an opportunity to optimize the screening process via computer vision. Although only 10% of the lung cancer cases in our patients remain unscreened, we show the potential for deep learning models to increase the accuracy, consistency and adoption of lung cancer screening worldwide.

To move beyond the limitations of prior CADe and CADx approaches, we aimed to build an end-to-end approach performing both localization and lung cancer risk categorization tasks using the input CT data alone. More specifically, we were interested in building a system that can automatically screen a patient's entire LDCT volume, focus on regions of concern, comparison to prior imaging when available and calibration against biopsy reports and death certificates.

Another important high-level decision in our approach was to learn features using deep convolutional neural networks (CNN), rather than using hand-engineered features such as texture, feature space and region-based metrics. We chose CNN features because this approach has repeatedly been superior to hand-engineered features in many open computer vision competitions in the past few years, including the Kaggle 2017 Data Science Bowl which used NLST data.²²

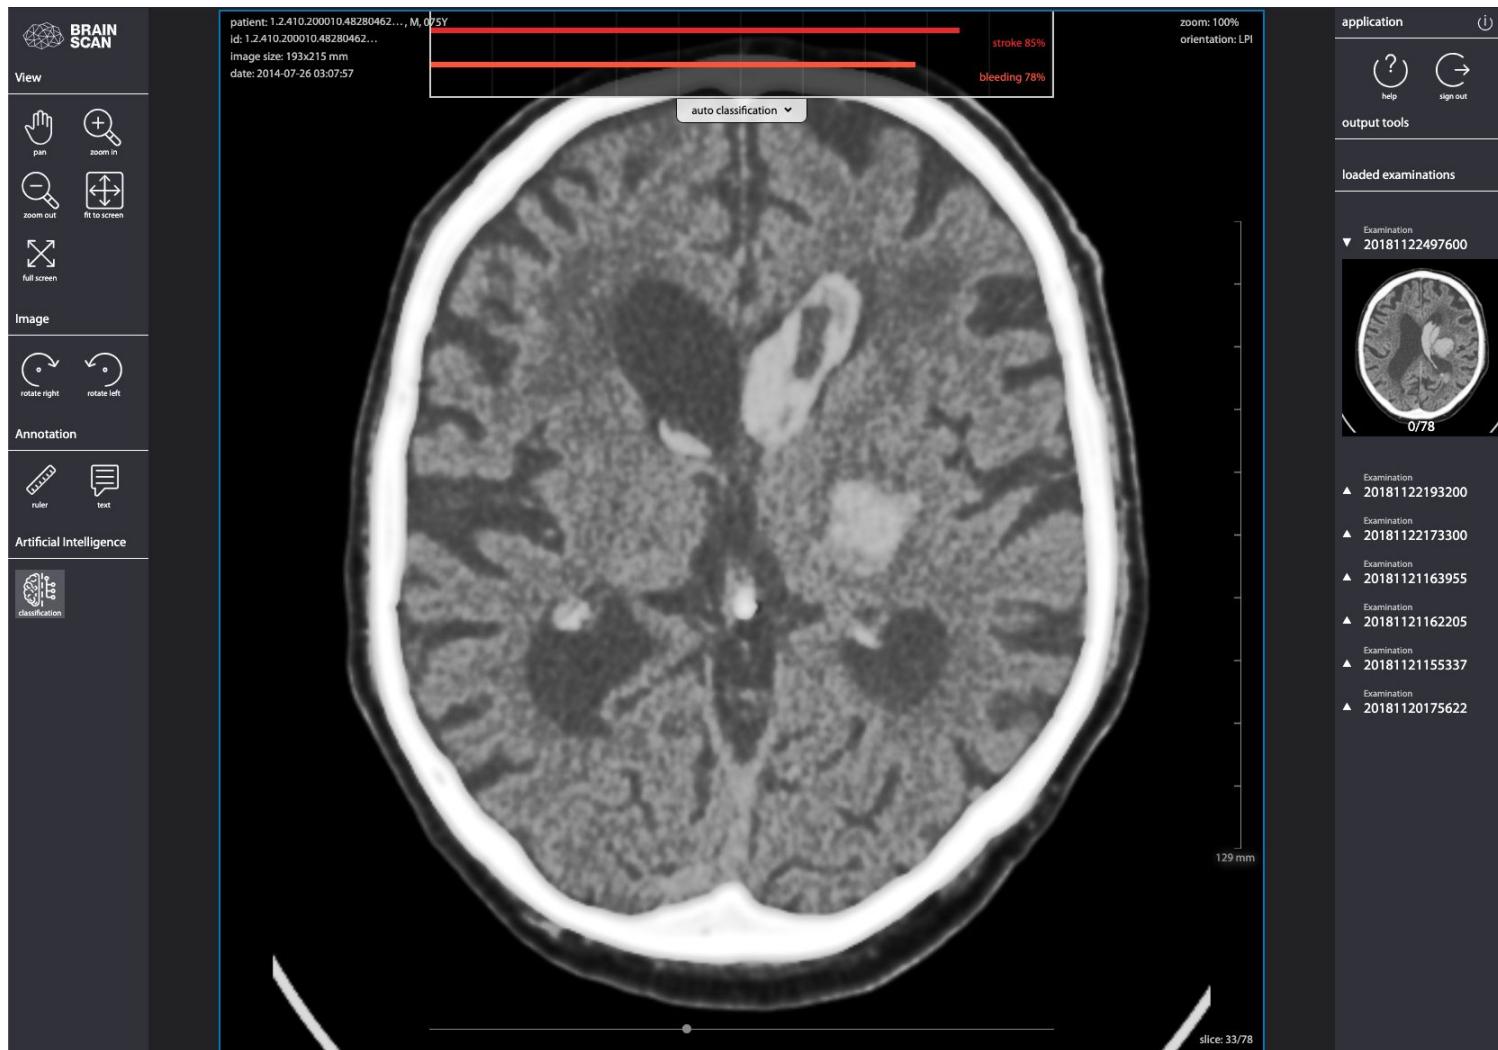
There were three key components in our new approach (Fig. 1). First, we constructed a three-dimensional (3D) CNN model that performs end-to-end analysis of whole-CT volumes, using LDCT

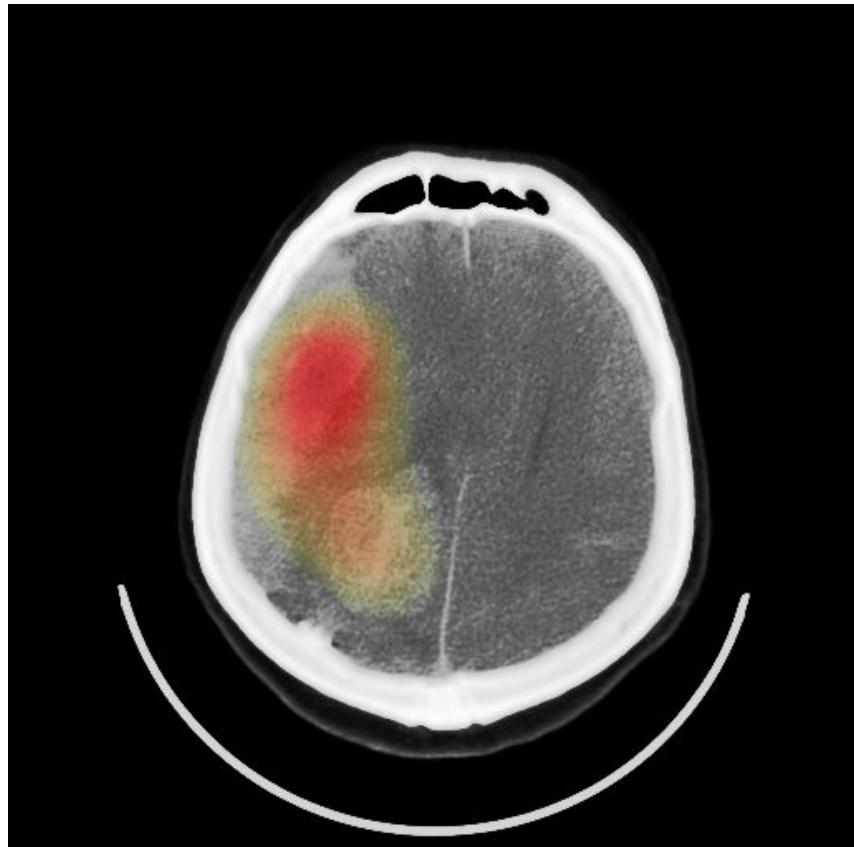
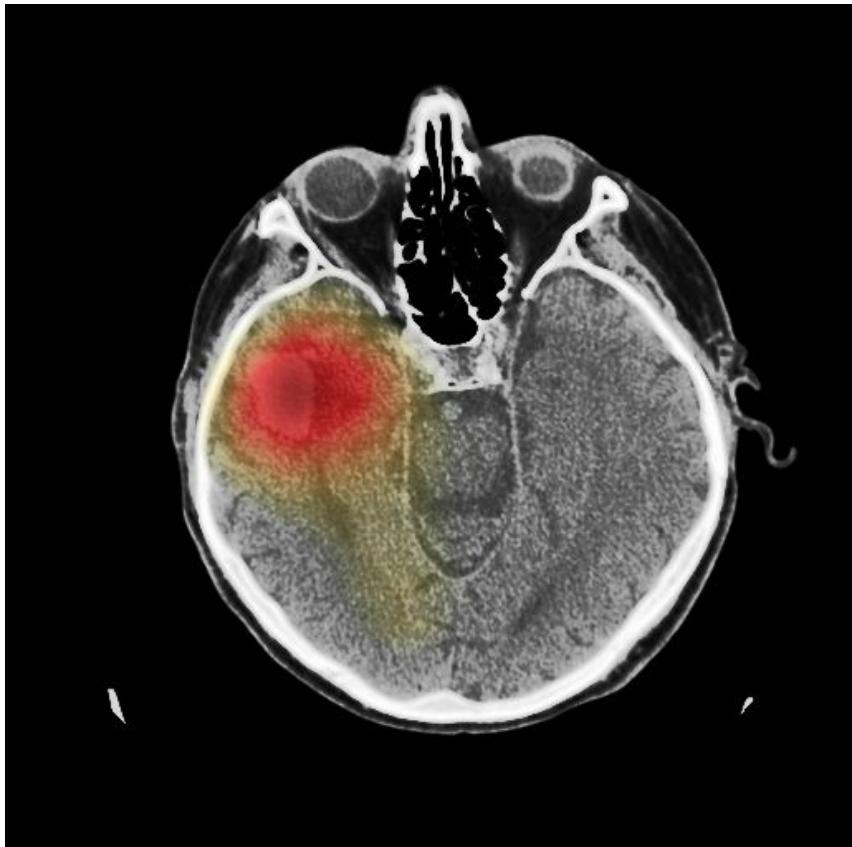
¹Google AI, Mountain View, CA, USA; ²Stanford Health Care and Palo Alto Veterans Affairs, Palo Alto, CA, USA; ³Northwestern Medicine, Chicago, IL, USA; ⁴New York University-Langone Medical Center, Center for Experimental Image, New York City, NY, USA; ⁵These authors contributed equally: Diego Ardila, Atilla P. Kiraly, Sujeeth Bharadwaj, Bokyung Choi, David P. Naidich, Shravya Shetty

NATURE MEDICINE | www.nature.com/naturemedicine/

The Nature trademark is a registered trademark of Springer Nature Limited.

Interfejs demonstracyjny

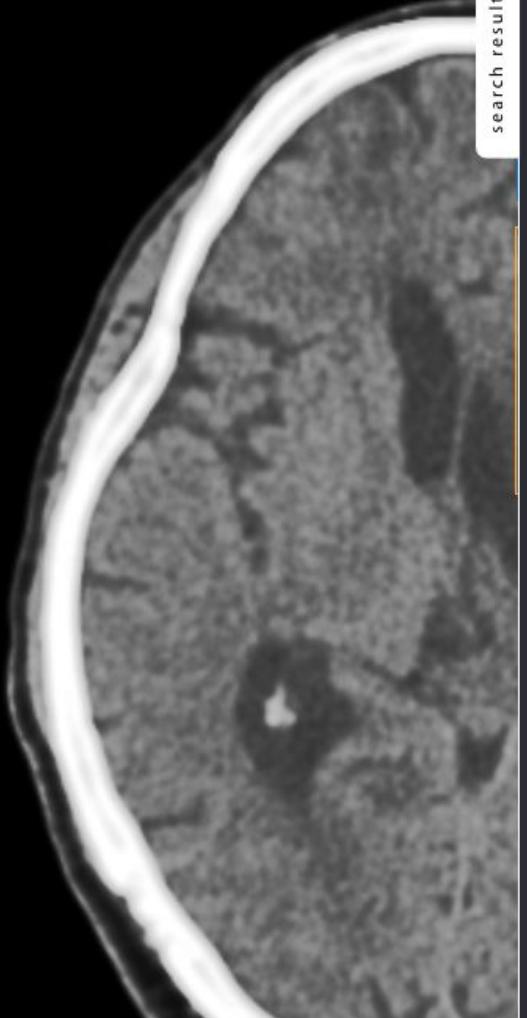




Wyszukiwanie podobnych przypadków w bazie

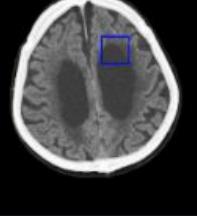
patient: 1.2.410.200010.48280462..., M, 062Y
id: 1.2.410.200010.48280462...
image size: 189x209 mm
date: 2014-10-09 13:39:22

auto cla: search results



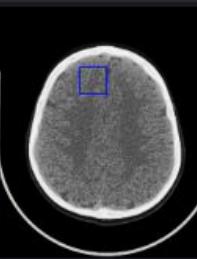
Uogólnione nasiłone zaniki korowo-podkorowe, najsilniej wyrażone podnamiotowo. Masywnie poszerzony układ komorowy, z nieco nierównym brzegiem boczny lewej komory bocznej (w wyniku wchłonięcia malacji okołokomorowych?) Wódociąg mózgu drożny, bez ewidentnych cech nadciśnienia wewnętrzkomorowego. Krwawienia śródmiążgowego i przymiążgowego aniciasnoty wewnętrzczaszkowej stwierdzam. Jednoznacznie świeżą zmianaczyliopochodnych w badaniu widać. U podstawy lewego płata czołowego obszar malacji, mniejszy w podobnej lokalizacji po stronie przeciwcnej. Hipodensja okołokomorowej istoty białej jako wyraz niedostateczności krążenia mózgowego wyraźnie większa niż poprzednio. Zwapnienia w naczyniach podstawy mózgu. Kości czaszki bez zmian urazowych. Pneumatyzacja kości skroniowych obustronne w normie. Częściowe zacieśnienie komórek sitowia, zacieśnienie prawej zatoki czołowej, polipowe zgrubienia w prawej zatoce szczękowej.

similarity 26%

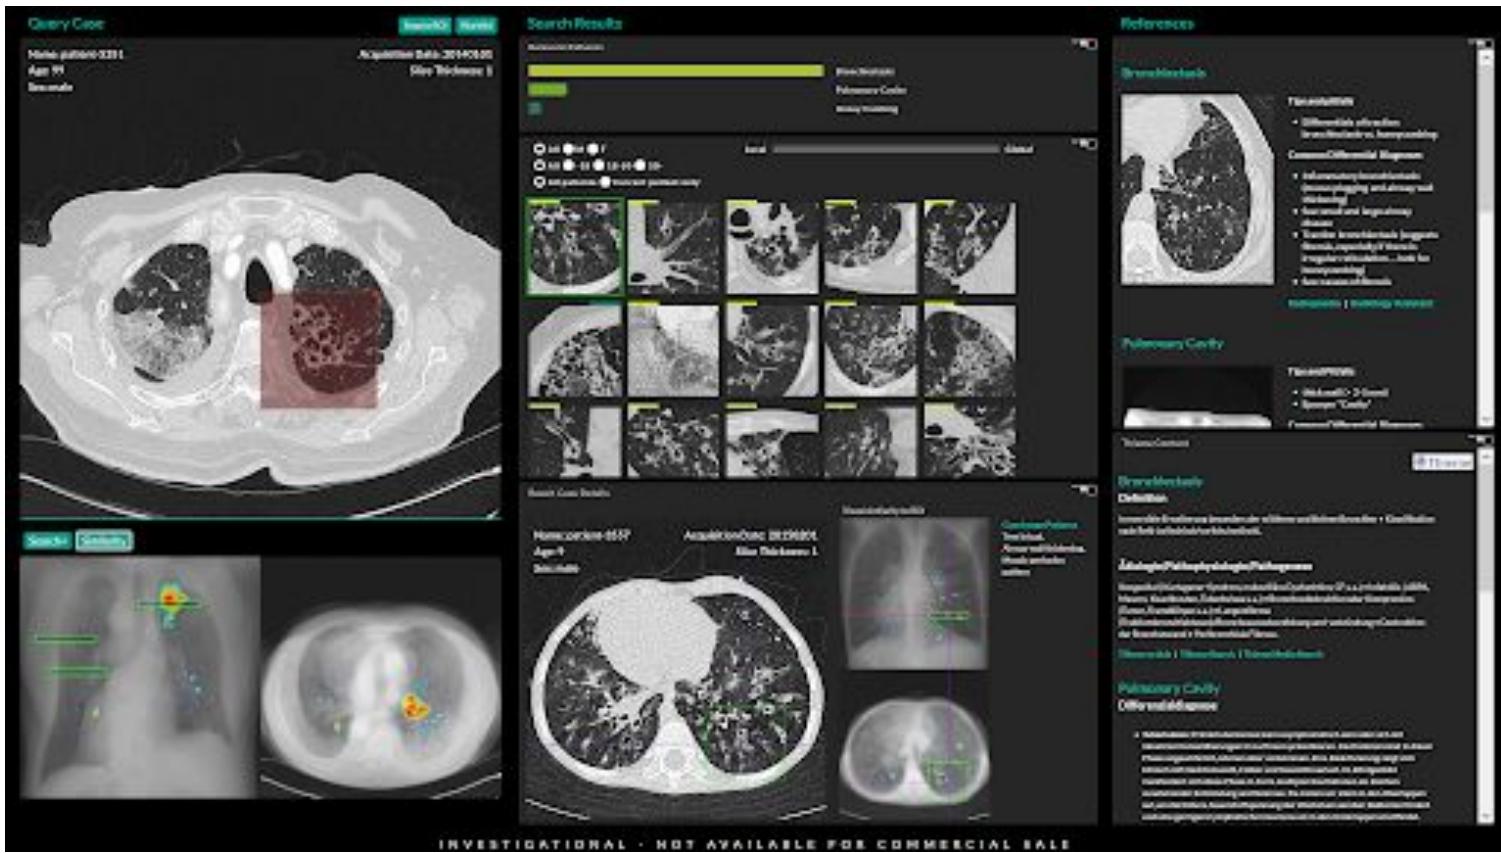


Mózgowie bez zmian ogniskowych. Cech świeżego niedokrvenia nie stwierdza się. Nie stwierdza się obecności krawienia śród-, ani namóżgowego. Układ komorowy symetryczny, nieposzerzony. Przestrzenie podpajęczynówkowe prawidłowe. Kości czaszki bez zmian urazowych. Zwraca uwagę pogrubienie lewego skrzydła większego kości klinowej oraz zmatowienie jego struktury kostnej - dysplazja włóknista?, innie? - wskazana konsultacja ortopedyczna

similarity 81%



Konkurencyjny startup - ContextFlow

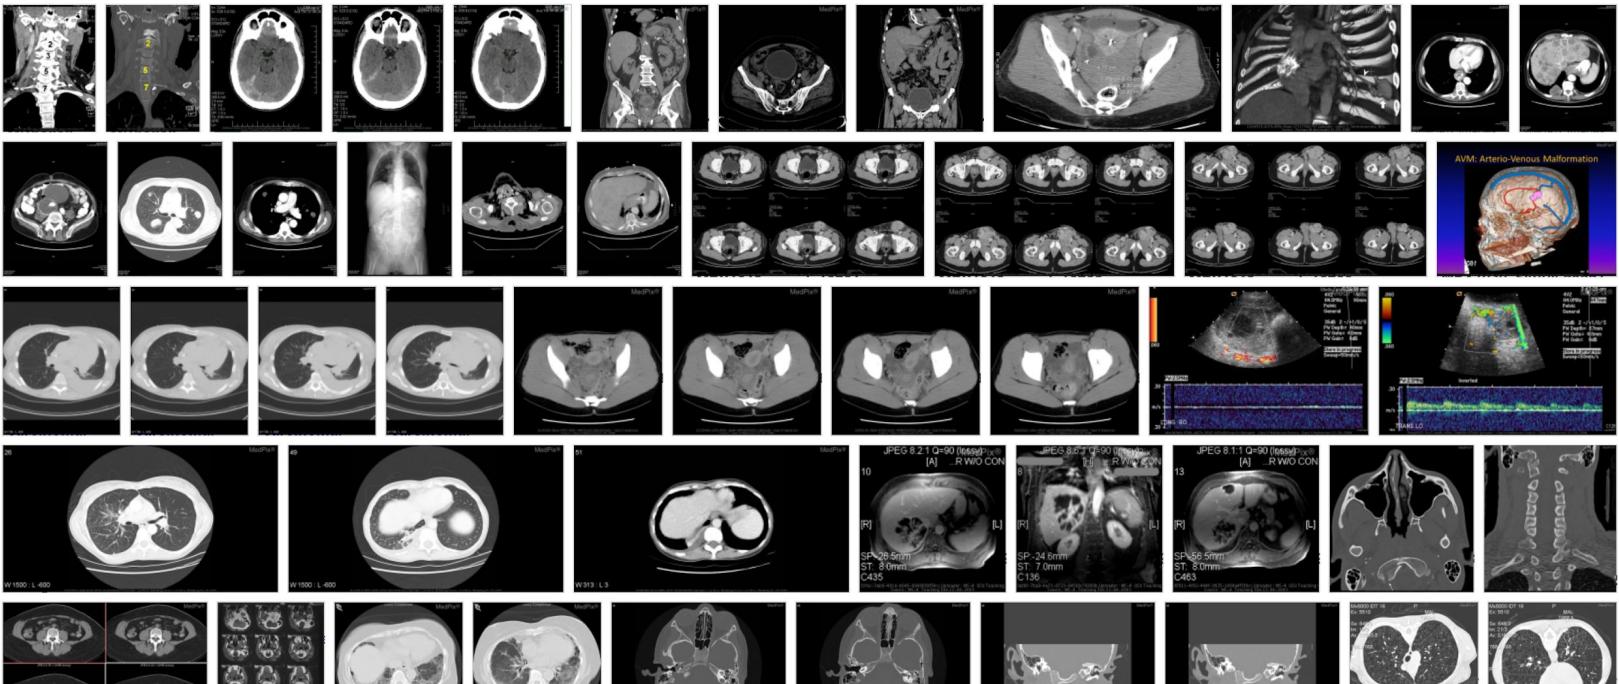


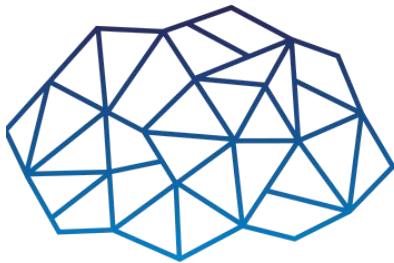
Wyszukiwanie przypadków podobnych w bazie

OPEN i® Search by text or dropping an image. o Q View as grid list

Limits: Rank By Article Type Image Type Subsets Collections License Type Specialties Search In API FAQ Recent Searches

Image Type: Exclude Graphics CT Scan





**BRAIN
SCAN**

BrainScan – System wspomagający analizę badań
obrazowych TK głowy

www.brainscan.ai