

Sztuczna inteligencja w medycynie na przykładzie rozpoznawania złośliwości guzów nerek

Aleksander Obuchowski

Lead AI architect @  Radiato.ai

PROJEKTY

- System TITAN do rozpoznawania złośliwości guzów nerek
- System MORFEUSZ do diagnostyki COVID na podstawie morfologii
- Parametryzacja opisów lekarskich
- Przewidywanie COVID na podstawie zdjęć rentgenowskich

System TITAN do diagnostyki złośliwości guzów nerek

PROBLEM

- Nawet **15-20%** operacji usunięcia guzów nerek (nefrektomii) wykonywanych jest niepotrzebnie.
- W Polsce jest to ponad **900** operacji które niepotrzebnie narażają zdrowie pacjentów
- U **30%** pacjentów hospitalizowanych z powodu koronawirusa zaobserwowano powikłania związane z nerkami
- Maleje liczba specjalistów podczas gdy ilość guzów rośnie

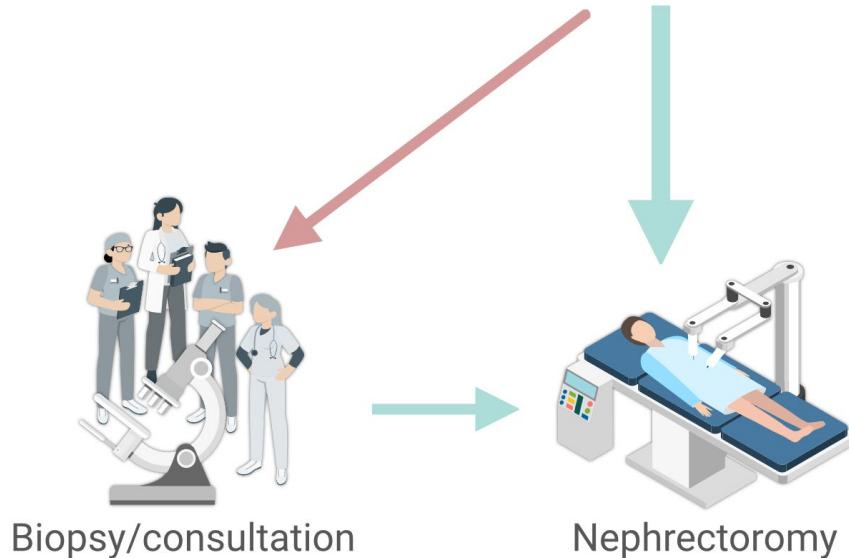
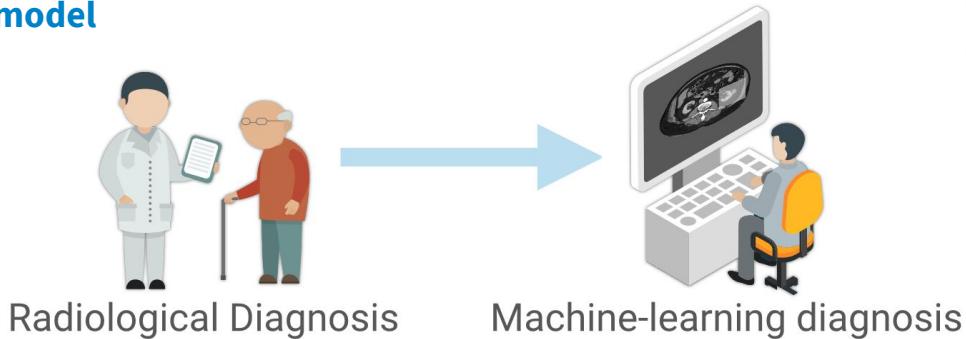


Machine aided diagnosis system

- Przyspieszenie systemu diagnostycznego
- Zwiększa precyzja
- Łatwa skalowalność
- Samodoskonalący się system
- Zwiększa świadomość pacjenta



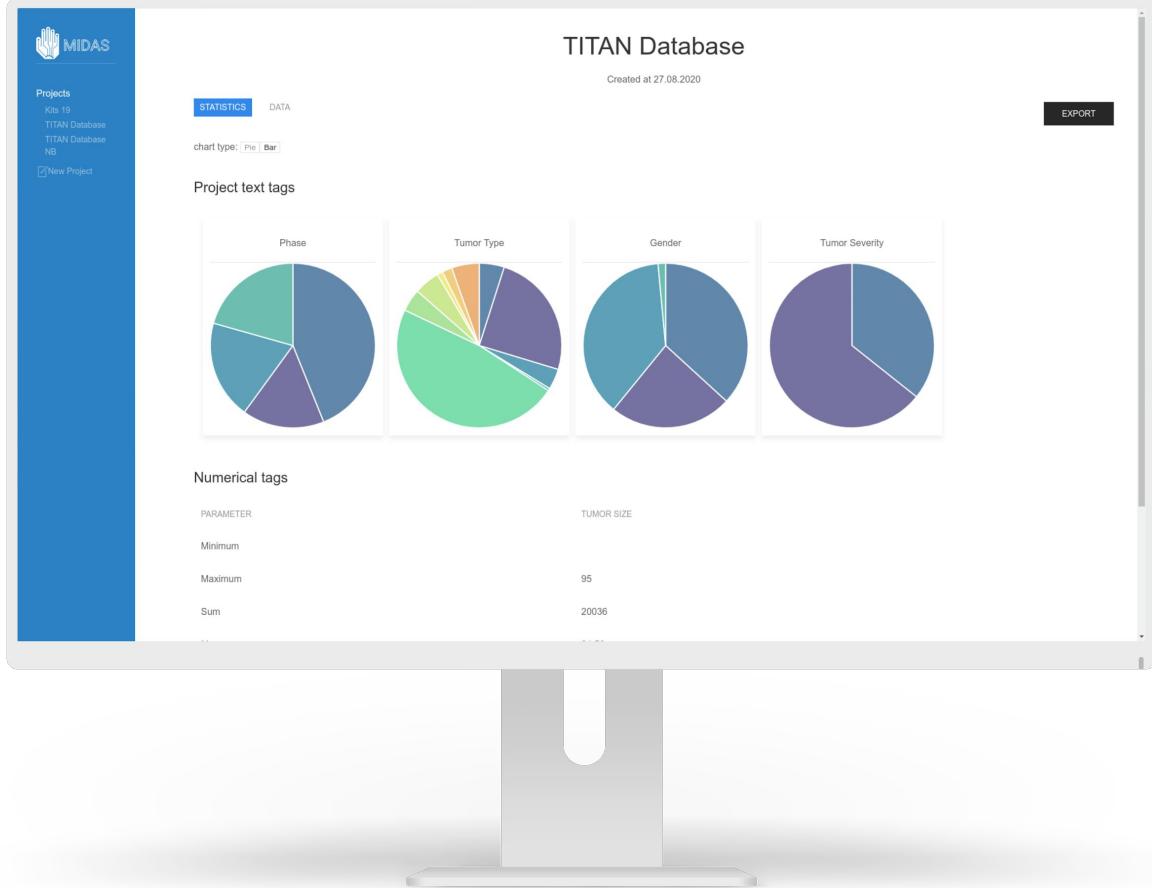
Human-Machine meta model



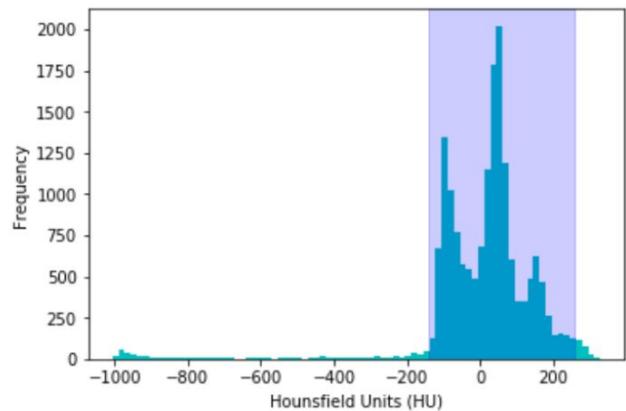
Dataset

- 15 485 obrazów
- 383 przypadków

Tumor type	No. of cases	No. of images
ccRCC	214	10193
chRCC	26	1590
pRCC-type-1	10	488
pRCC-type-2	3	324
pRCC	27	769
malignant-other	1	75
oncocytoma	20	702
AML	78	1221
benign-other	4	123
malignant tumors	281	13439
benign tumors	102	2046
total	383	15485



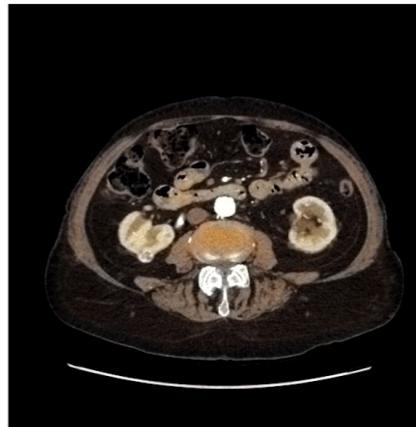
Pre-processing



Dataset	No. of images
full cut	7854
middle cut	2512
one image	358



Colorization

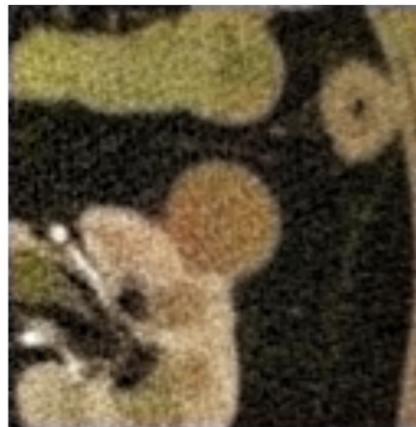


(a) Abdomen: Original Image

(b) Abdomen: LTBC

(c) Abdomen: LRAC

(d) Abdomen: CIC



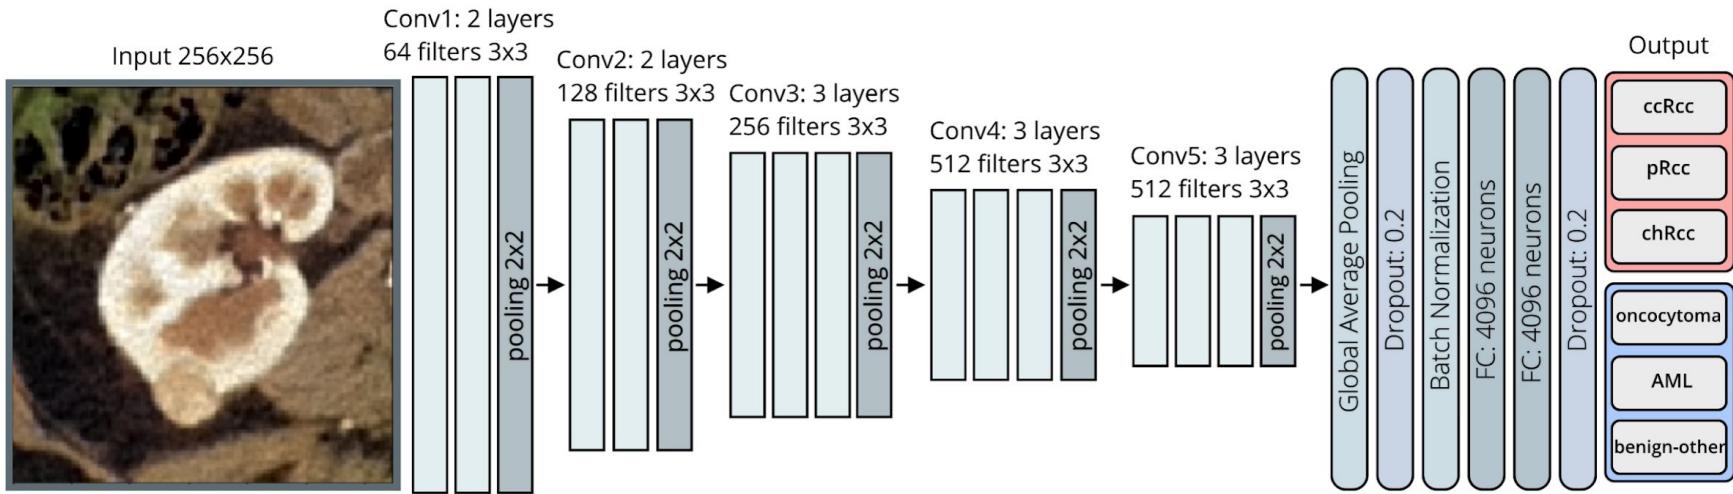
(e) Tumor: Original Image

(f) Tumor: LTBC

(g) Tumor: LRAC

(h) Tumor: CIC

Architecture



Experiments and results

Subtype pooling

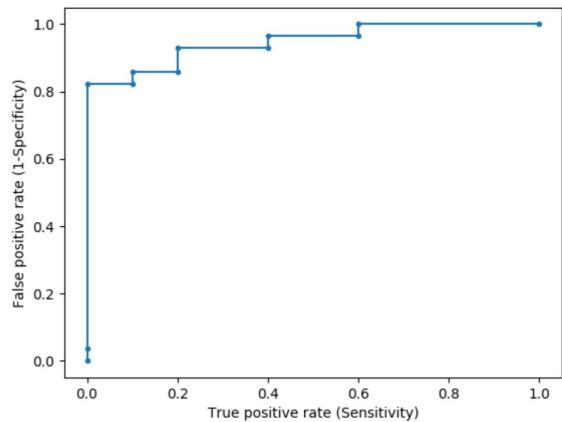
Model	Binary	Subtype pooling
DenseNet	0.7435	0.736
MobileNet	0.7430	0.769
Xception	0.769	0.743
InceptionV3	0.743	0.769
CheXnet	0.743	0.769
VGG19	0.743	0.820
VGG16	0.794	0.820

Colorization

Model	Colorized – one	Colorized – middle
DenseNet	0.743	0.736
MobileNet	0.743	0.736
Xception	0.743	0.736
InceptionV3	0.743	0.842
CheXnet	0.769	0.736
VGG19	0.666	0.789
VGG16	0.769	0.868

Final Solution

- Skuteczność 87%
- 10/10 poprawnie rozpoznanych guzów łagodnych

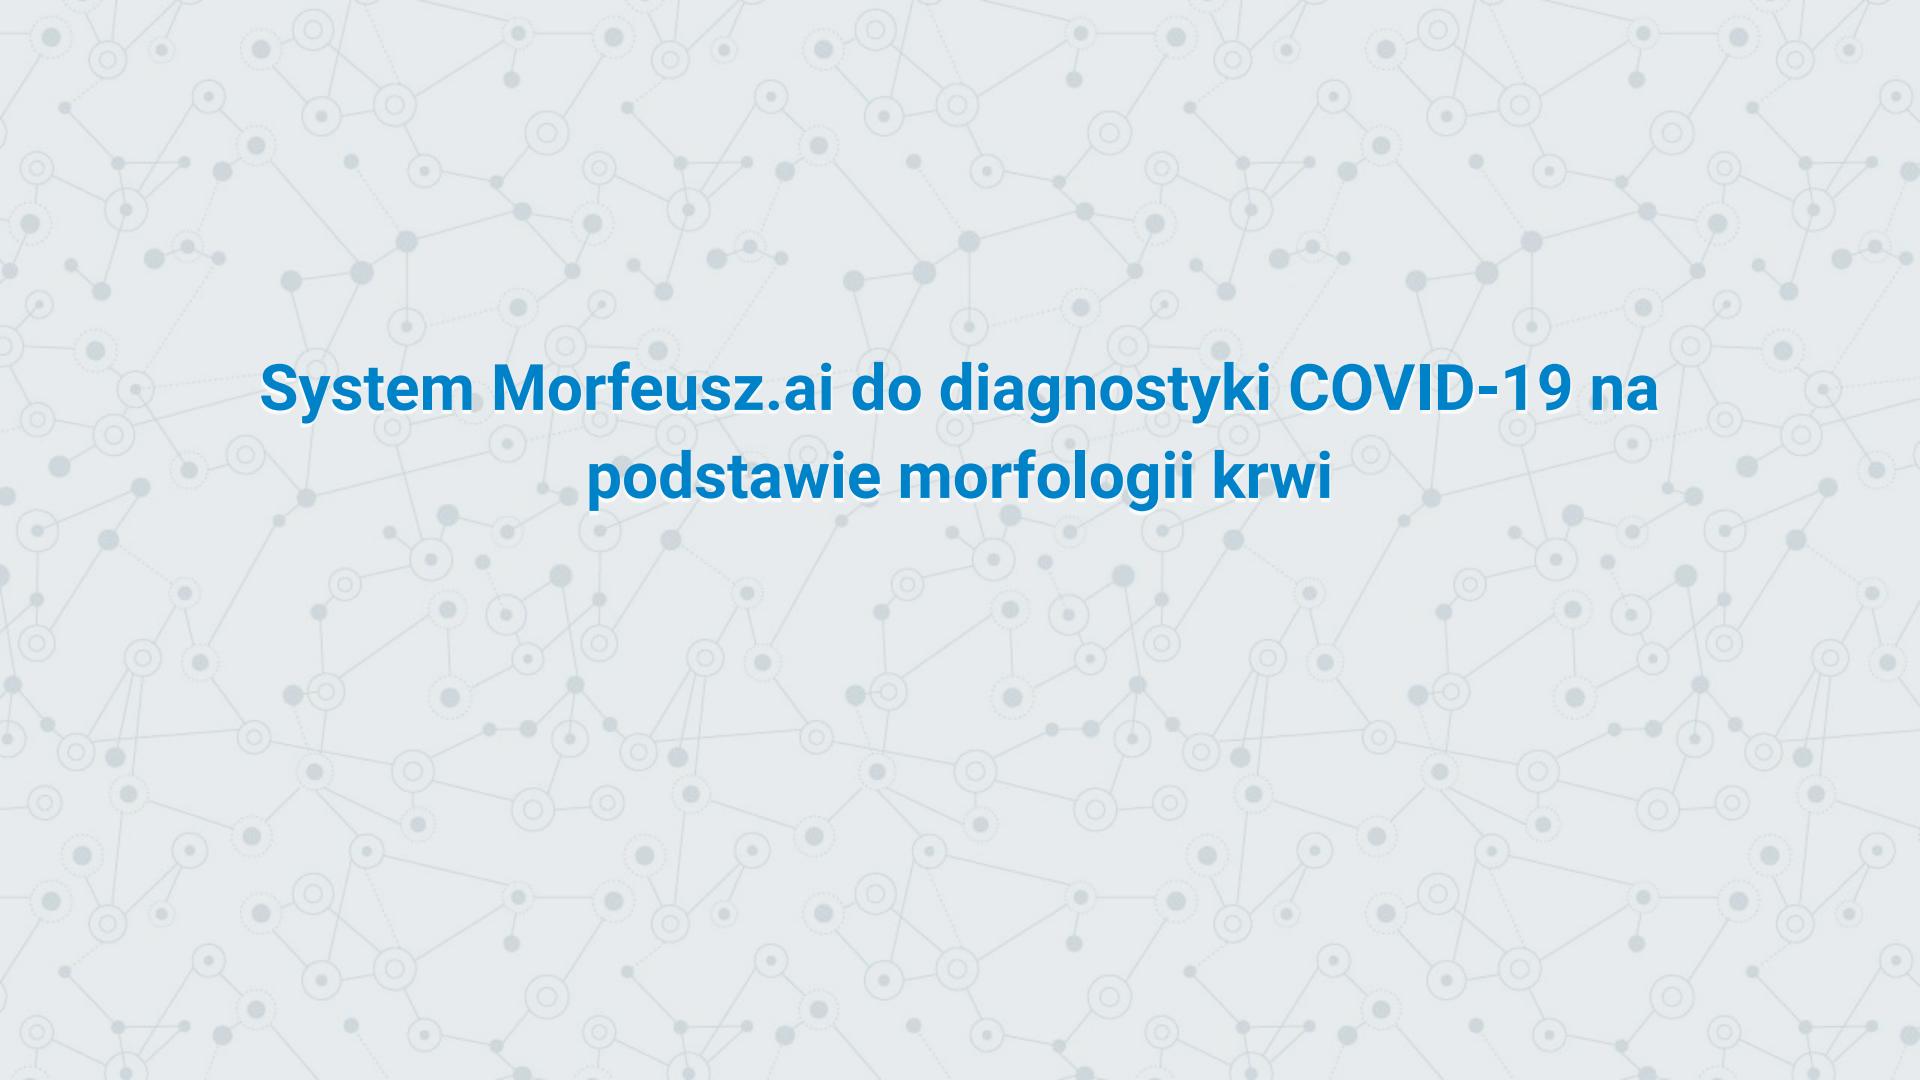


Histopathology results

Machine diagnosis	Malignant	Benign
	Malignant	Benign
Malignant	23	0
Benign	5	10

Key takeaways

- Specjaliści i systemy uczenia maszynowego mogą działać wspólnie w schemacie meta-modelingu
- Transfer wiedzy pomiędzy naturalnymi a medycznymi obrazami może być ulepszony dzięki koloryzacji
- Użycie bardziej szczegółowych klas podczas treningu może zwiększyć skuteczność rozpoznania ogólnych klas

A light gray background featuring a complex network of interconnected nodes, some with dashed outlines, representing a system of connections or data flow.

System Morfeusz.ai do diagnostyki COVID-19 na podstawie morfologii krwi

Model przewidujący występowanie COVID-19 na podstawie badań morfologii

Zbiór danych

Table 7.1: Class distribution over dataset

Diagnosis	Count
Negative	19013
Positive	546

Table 7.2: Correlation between CBC features (for values greater than 0.5)

feature 1	feature 2	correlation coefficient
Hemoglobin	Hematocrit	0.972
% of Neutrophils	% of Lymphocytes	0.947
Red blood cell count	Hematocrit	0.919
Hemoglobin	Red blood cell count	0.888
White Blood Cell Count	Neutrophil Count	0.546
Hemoglobin	Red Cell Distribution Width	0.506

Model przewidujący występowanie COVID-19 na podstawie badań morfologii

Table 7.3: CBC features used in classification

Attributes
Red blood cell count
Mean Corpuscular Hemoglobin
Mean Corpuscular Hemoglobin Concentration
Red Cell Distribution Width
Platelet Count
Mean Platelet Volume
White Blood Cell Count
Immunoglobulins
% of Lymphocytes
% of Monocytes
% of Eosinophils
% of Basocytes
% of Erythrocytoblasts

Balansowanie danych

Synthetic Minority Oversampling Technique

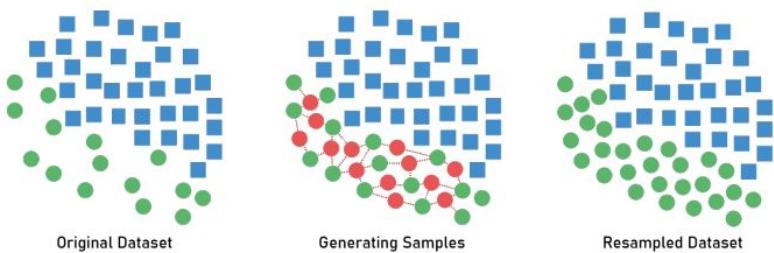


Figure 7.1: SMOTE data generation visualization [75]

Model przewidujący występowanie COVID-19 na podstawie badań morfologii

Model

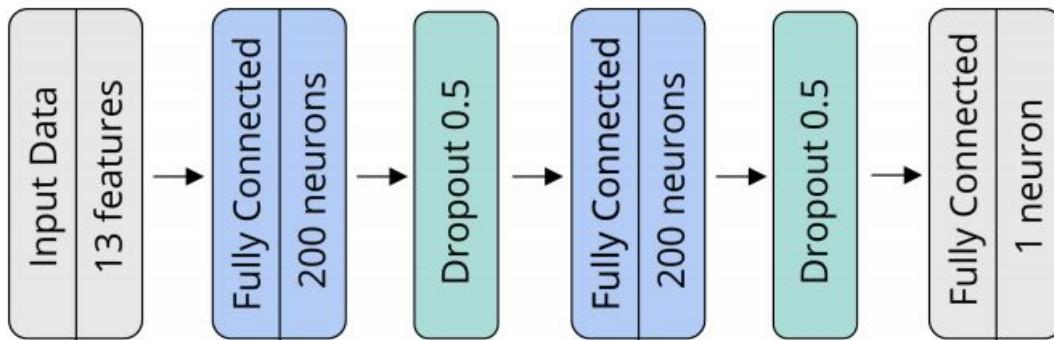


Figure 7.2: Classification model

Model przewidujący występowanie COVID-19 na podstawie badań morfologii

Wyniki

Table 7.4: Results

Accuracy	97 %
AUC	74 %

Parametryzacja opisów medycznych



Język Metaetykietator

By [drcz](#) @ [sentione](#)

Listing 5.1: MTT script example

```
LABEL "snow" "is" ("white"|"yellow") AS @"color_statement"
LABEL ("Alfred"|"Frank") "says" @"color_statement" AS @"indirect_speech"
UNLABEL @"color_statement" IN @"indirect_speech"
```



Model parametryzowania opisów lekarskich

Listing 5.2: Heart model

```
LABEL (a"serce" | a"sylwetka" a"serca" | a"sylwetka" a"sercowo" a"--" a"naczyniowa") AS @"SERCE"
LABEL @"SERCE" (a"i" _ |) (a"rtg" |) ((a"wielkoscia" |) a"w" a"normie" | ar"niepwiekszon(e|a)" | ar"nieposzerzon(e|a)" | a"w" (_|) ar"granic(y|ach)" (_|) (ar"norm(y|)"|a"n")) AS @"SERCE W NORMIE"
LABEL a"prawidlowa" @"SERCE" AS @"SERCE W NORMIE"
LABEL @"SERCE" (_|) (ar"powiekson(e|a)"|a"wieksze") AS @"SERCE POWIĘKSZONE"
LABEL @"SERCE" (_|) a"podparte" a"na" a"przeponie" AS @"SERCE PODPARTE NA PRZEPONIE"
LABEL (_|) ar"powiekson(e|a)" @"SERCE" AS @"SERCE POWIĘKSZONE"
LABEL @"SERCE" (a"nie" | ar"trudn(e|a)") a"do" a"oceny" AS @"SERCE NIE DO OCENY"
LABEL a"rtg" AS @"RTG"
UNLABEL @"SERCE" IN @"SERCE W NORMIE"
UNLABEL @"SERCE" IN @"SERCE POWIĘKSZONE"
UNLABEL @"SERCE" IN @"SERCE PODPARTE NA PRZEPONIE"
UNLABEL @"SERCE" IN @"SERCE NIE DO OCENY"
```

Model parametryzowania opisów lekarskich

Wyniki - model opisów serca

Tag (pl)	Tag (en)	Count
Serce w normie	Normal heart size	1136
Serce powiększone	the heart is enlarged	300
Serce nie do oceny	heart borders difficult to distinguish	67
Serce podparte na przeponie	excessively horizontal position of the heart	47
Serce (other)	heart (other)	184

Precyzja : 89%

Model parametryzowania opisów lekarskich

Wyniki - model opisów serca

Tag (pl)	Tag (en)	Count
Serce w normie	Normal heart size	1136
Serce powiększone	the heart is enlarged	300
Serce nie do oceny	heart borders difficult to distinguish	67
Serce podparte na przeponie	excessively horizontal position of the heart	47
Serce (other)	heart (other)	184

Precyzja : 89%

Model parametryzowania opisów lekarskich

Tag (pl)	Tag (en)	Count
Płuca prawidłowo powietrzne	normaleration of lungs	117
Lewe płuco prawidłowo powietrzne	left lung normal	69
Prawe płuco prawidłowo powietrzne	right lung normal	38
Płuca bez cech zastoju	lungs with no pulmonary congestion	264
Płuca bez zmian ogniskowych	lungs with no focal lesions	504
Płuca bez zmian zapalnych	lungs with no pneumonic consolidation	37
Płuca bez zmian miąższowych	no parenchymal densities	34
Płuca bez zagęszczeń miąższowych	lungs with no pulmonary opacities	385
Płuca rozedmowe	emphysematous lungs	21
Płuca rozprężone	decompressed lungs	39
Zmniejszona powietrzność płuca	decreased general aeration of the lung	24
Płuca (inne)	lungs (other)	1031
Aorta wydłużona	elongated aorta	8
Aorta poszerzona	dilated aorta	10
Aorta zstępująca	descending aorta	5
Aorta kręta	tortuous aorta	23
Aorta miażdzycowa	atherosclerotic aorta	174
Aorta (inne)	aorta (other)	4
Wnęki płucne powiększone	dilated pulmonary hilum	19
Wnęki płucne naczyniowe	vascular pulmonary hilum	30
Wnęki płucne niepowiększone	normal hilar enlargement	71
Wnęki płucne (inne)	hilum (other)	28
Płyn w prawej jamie oplucrej	the right pleural effusion	282
Płyn w lewej jamie oplucreowej	the left pleural effusion	208
Płyn w obu jamach oplucrenych	the both pleural effusion	17
Lewa jama oplucreowa wolna	clear left pleural cavity	158
Prawa jama oplucreowa wolna	clear right pleural cavity	137
Jamy oplucreowe wolne od płynu	clear both pleural cavities	668
Brak odmy	no pneumotorax	282
Zręb	lung interstitial	16
Zmiany zapalne	pneumonic consolidation	31
Miąższ bez zagęszczeń	lung parenchymal without densities	50
Zgęszczenia zapalne	pneumonic opacity	8
Zmiany Siateczkowe	reticular opacities	9

Wyniki - model opisów płuc

Precyzja (płuca): 60%

Precyzja (aorta): 92%

Precyzja (wnęki płucne): 82%

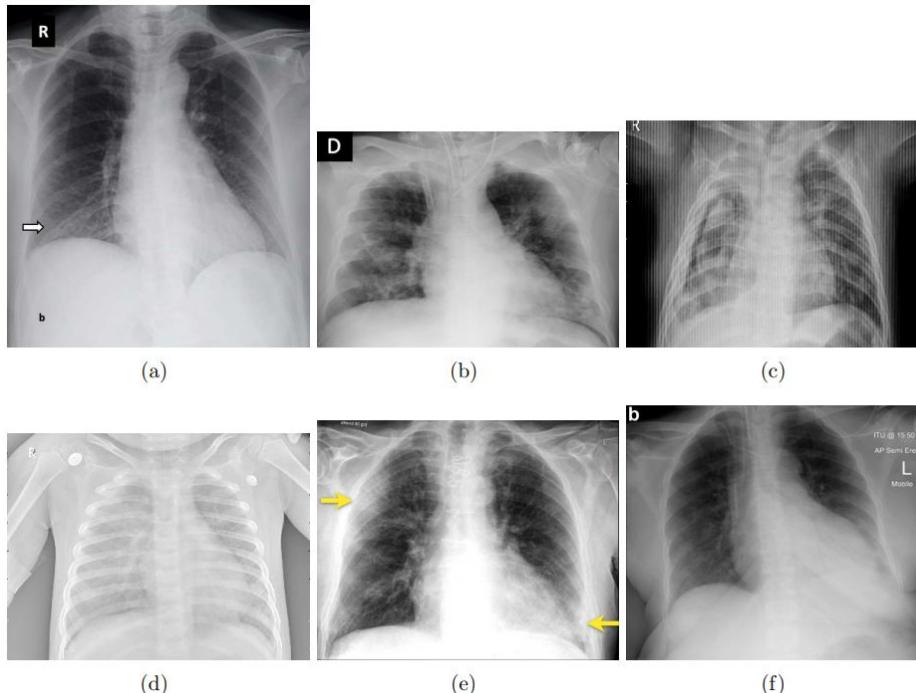
A light gray background featuring a complex network graph composed of numerous small, semi-transparent nodes connected by thin lines, creating a sense of data connectivity and complexity.

Przewidywanie Covid-19 na podstawie zdjęć rentgenowskich

Model przewidujący występowanie COVID-19 na podstawie zdjęć rentgenowskich

Zbiór danych

Class	Count
Normal	3270
Pneumonia-Bacterial	3001
Pneumonia-Viral	1656
COVID-19	1281
Total	9208



Analysis of X-ray scans with reports and complete blood count (CBC) tests and their applications in COVID-19 machine diagnosis based on artificial neural network
- A. Obuchowski & B. Rydziński <http://dx.doi.org/10.13140/RG.2.2.16411.18725>

Model przewidujący występowanie COVID-19 na podstawie zdjęć rentgenowskich

Architektury - VGG16

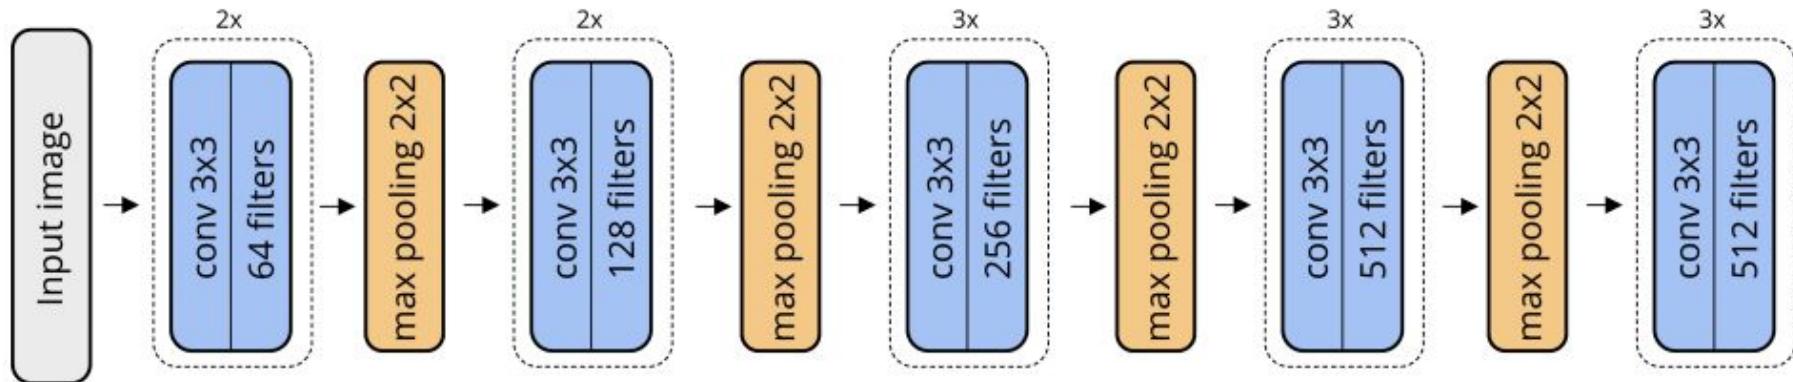


Figure 6.5: VGG16

Architektury - Inception V3

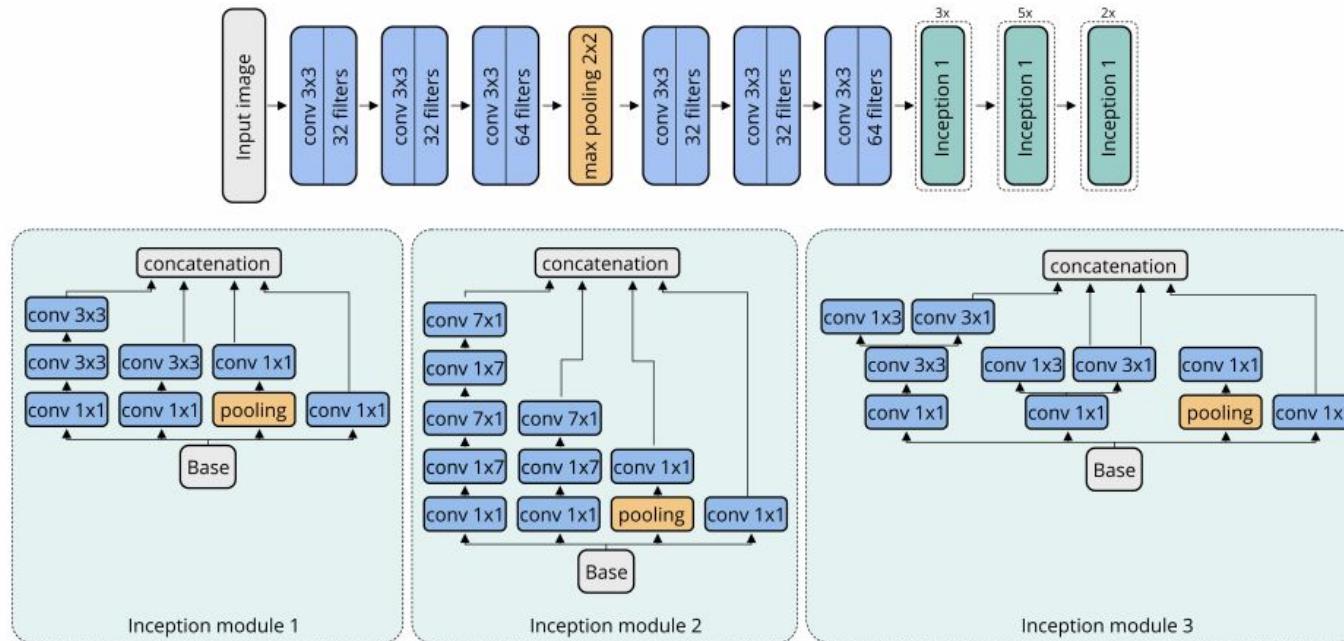


Figure 6.6: Inception V3

Analysis of X-ray scans with reports and complete blood count (CBC) tests and their applications in COVID-19 machine diagnosis based on artificial neural network
- A. Obuchowski & B. Rydziński <http://dx.doi.org/10.13140/RG.2.2.16411.18725>

Model przewidujący występowanie COVID-19 na podstawie zdjęć rentgenowskich

Architektury - ResNetV2

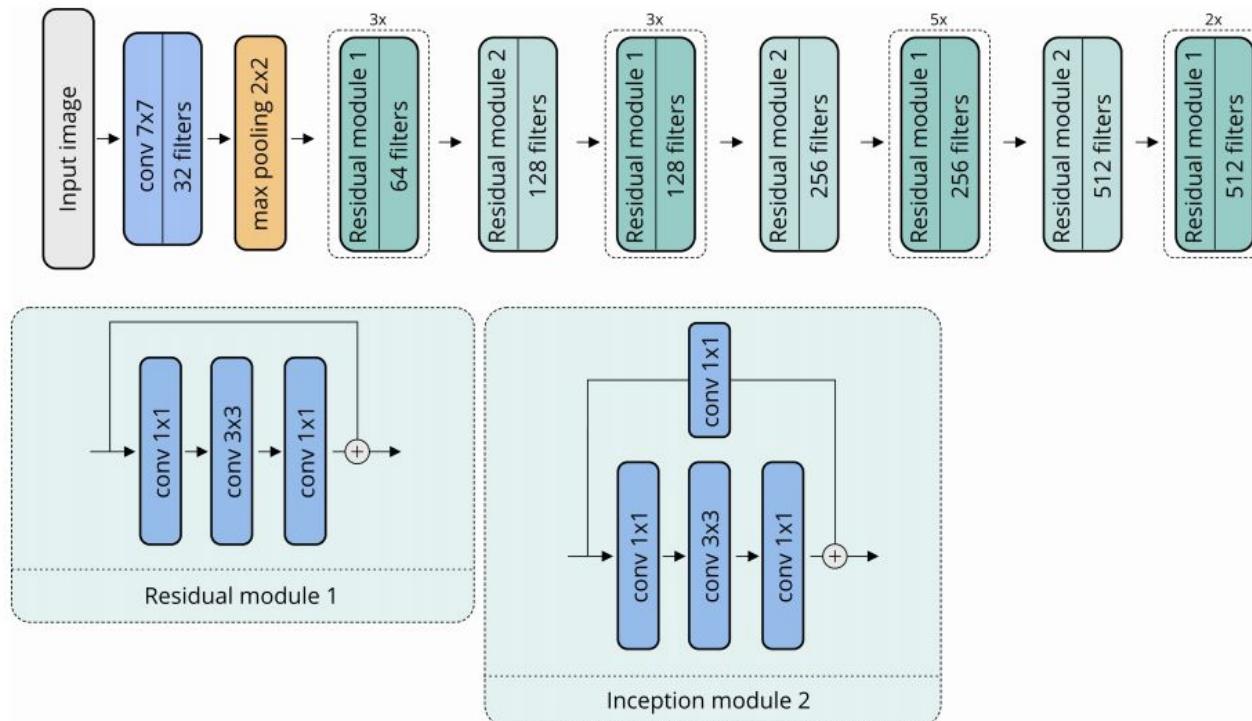
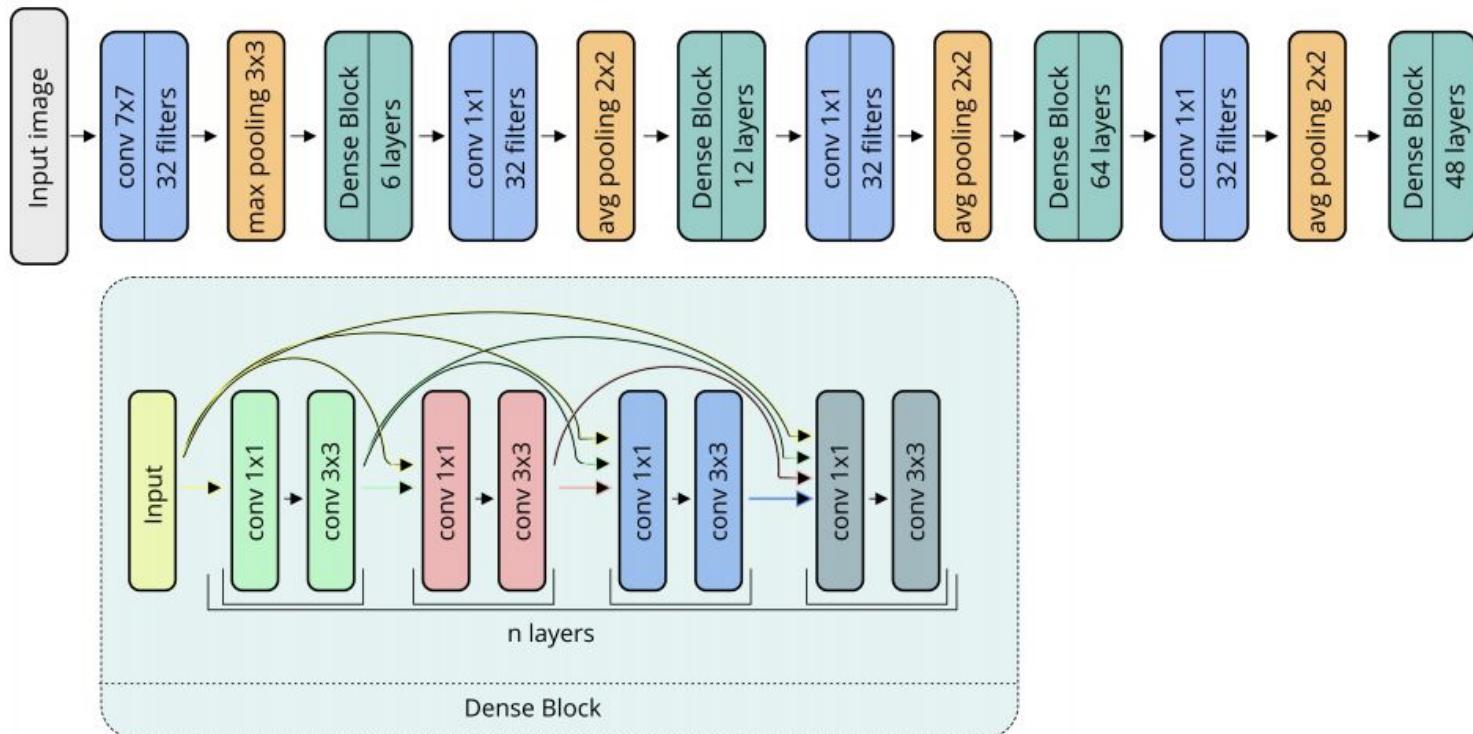


Figure 6.7: ResNetV2 architecture

Analysis of X-ray scans with reports and complete blood count (CBC) tests and their applications in COVID-19 machine diagnosis based on artificial neural network
- A. Obuchowski & B. Rydziński <http://dx.doi.org/10.13140/RG.2.2.16411.18725>

Architektury - DenseNet



Analysis of X-ray scans with reports and complete blood count (CBC) tests and their applications in COVID-19 machine diagnosis based on artificial neural network
- A. Obuchowski & B. Rydziński <http://dx.doi.org/10.13140/RG.2.2.16411.18725>

Transfer Learning - DenseNet

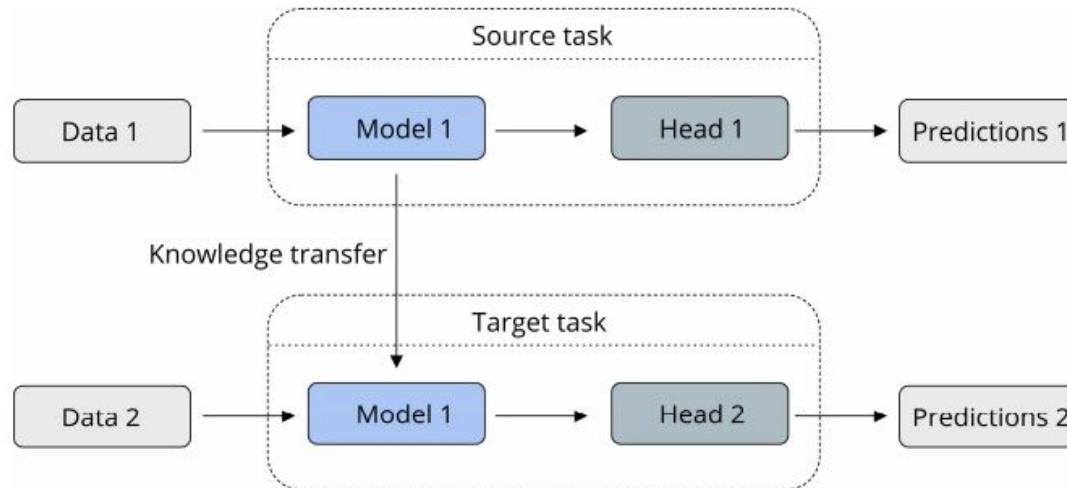


Figure 6.9: Transfer Learning

Warstwy klasyfikacyjne

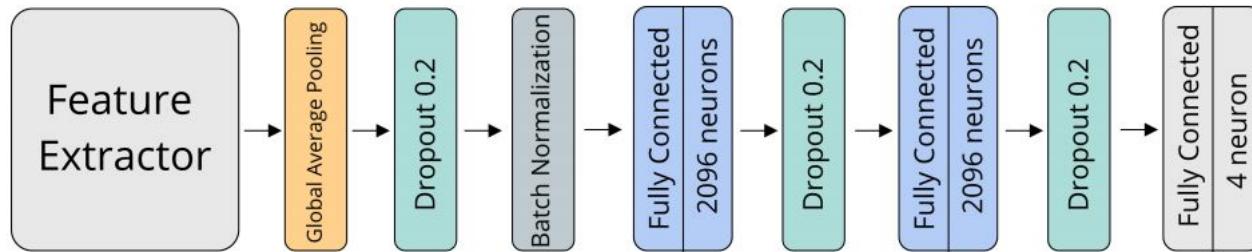


Figure 6.10: Classification model

Wyniki

Klasyfikacja 4 klasowa

Architecture	F1
DenseNet	0.748
Inception V3	0.772
ResNetV2	0.785
VGG16	0.856

Transfer Learning (RQ.3.3)

Architecture	F1
DenseNet (ImageNet)	0.748
CheXNet	0.826

Multi task learning (RQ.3.2)

Architecture	F1 (4 class training)	F1 (2 class traning)
Inception V3	0.906	0.968
DenseNet	0.923	0.93
CheXNet	0.935	0.93
ResNetV2	0.925	0.956
VGG16	0.965	0.961

Ostateczne rozwiązanie

Table 6.5: Confusion matrix of the final model

Model output	True diagnosis		Total
	Positive	Negative	
Positive	123	8	128
Negative	5	785	190
Total	128	793	

Table 6.6: Results of the final model

Metric	Score
f1	0.968
precision	0.976
recall	0.960

Dziękujemy za uwagę

Aleksander Obuchowski



obuchowskialeksander@gmail.com

e-Pionier

