

# Przetwarzanie obrazów hiperspektralnych: modele statystyczne i sieci neuronowe w trzech przykładach

dr hab. inż. Przemysław Głomb  
(pglomb@iitis.pl)

Instytut Informatyki Teoretycznej i Stosowanej PAN



## → Plan prezentacji

**Wstęp**

**Obrazowanie hiperspektralne**

**Przetwarzanie HSI: klasyczne algorytmy statystyczne**

**Przetwarzanie HSI: algorytmy kombinowane, statystyczne + neuronowe**

**Przetwarzanie HSI: algorytmy w pełni neuronowe**

**Geneza i podsumowanie**

# → Plan prezentacji

**Wstęp**

**Obrazowanie hiperspektralne**

**Przetwarzanie HSI: klasyczne algorytmy statystyczne**

**Przetwarzanie HSI: algorytmy kombinowane, statystyczne + neuronowe**

**Przetwarzanie HSI: algorytmy w pełni neuronowe**

**Geneza i podsumowanie**

## → IITiS PAN ([www.iitis.pl](http://www.iitis.pl))

1. Jeden z trzech instytutów PAN w dyscyplinie informatyka (obok IPI PAN i IBS PAN)
2. Kierunki badawcze
  - 2.1 Sieci komputerowe wraz z Internetem Rzeczy (IoT)
  - 2.2 Systemy wizji komputerowej i multimedialne
  - 2.3 Informatyka kwantowa
3. Zespół Systemów Multimedialnych
  - 3.1 Systemy VR/AR
  - 3.2 Obrazowanie hiperspektralne (HSI)
  - 3.3 Uczenie maszynowe w obrazach HSI i szeregach czasowych



# → Plan prezentacji

Wstęp

**Obrazowanie hiperspektralne**

Przetwarzanie HSI: klasyczne algorytmy statystyczne

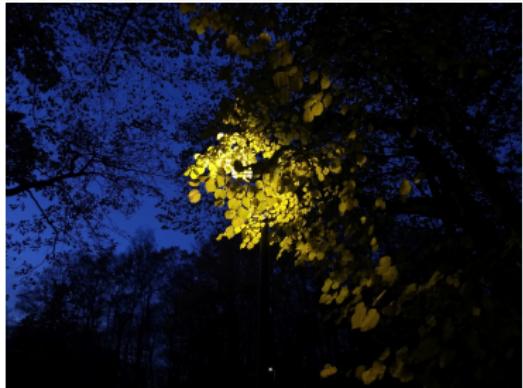
Przetwarzanie HSI: algorytmy kombinowane, statystyczne + neuronowe

Przetwarzanie HSI: algorytmy w pełni neuronowe

Geneza i podsumowanie



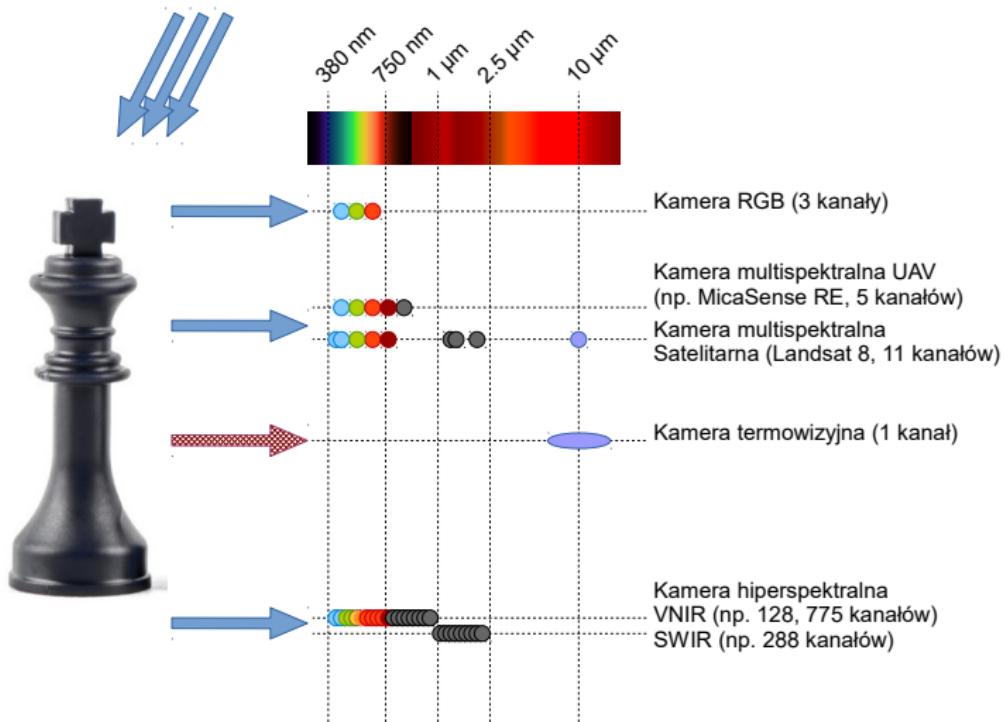
# Obrazowanie



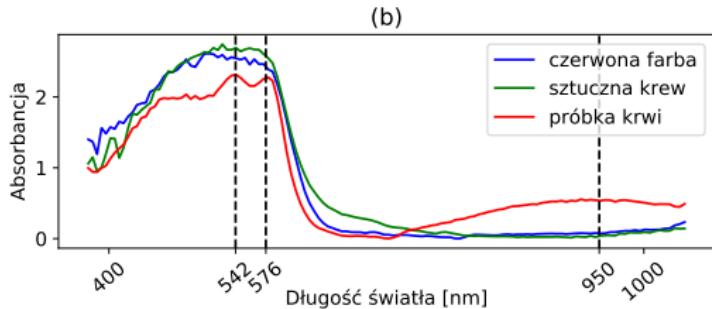
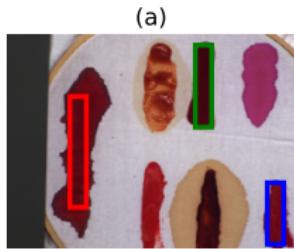


# Obrazowanie hiperspektralne<sup>a</sup>

<sup>a</sup>*Hyperspectral imaging, lub spektroskopia obrazowa, imaging spectroscopy*

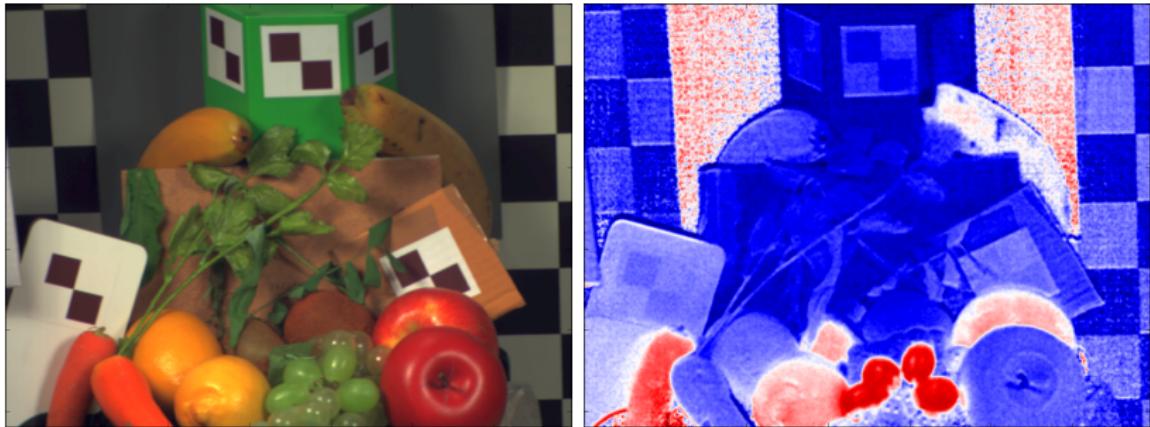


## Obrazowanie hiperspektralne



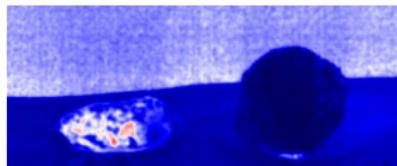
## ► Obrazowanie hiperspektralne

- Obraz RGB oraz reflektancja dla długości fali  $\approx 1000\text{nm}$

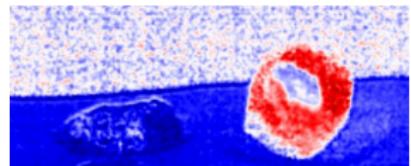


## ► Obrazowanie hiperspektralne

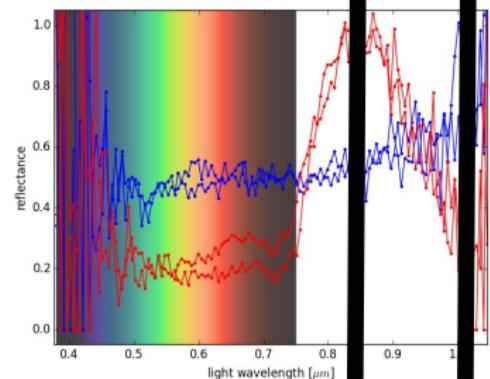
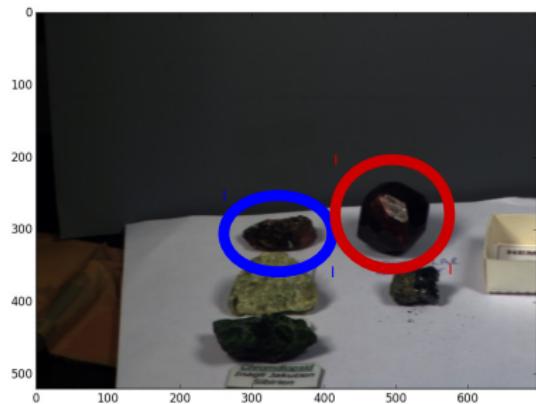
- Minerały Ałunit i Grossular, kamera SOC710-VP



842.19 nm

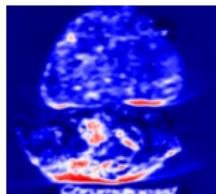


1012.29 nm

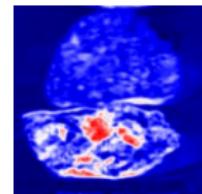


## ► Obrazowanie hiperspektralne

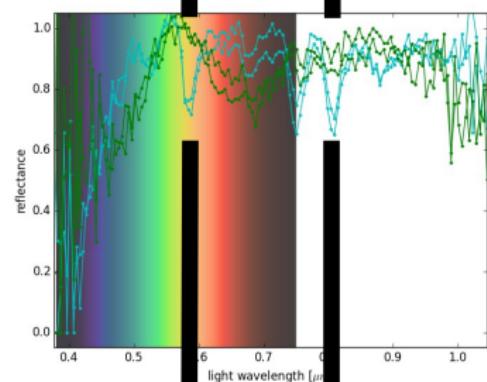
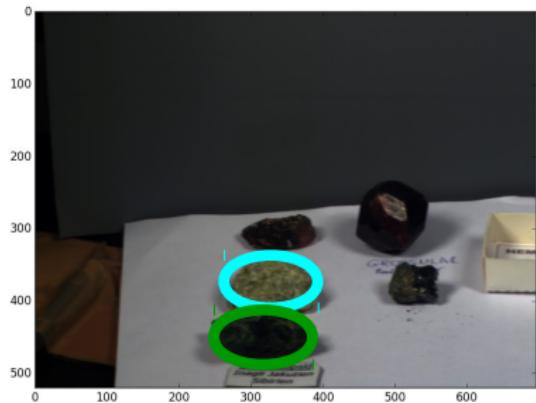
### ► Minerały Apatyt i Chromdiopsyd



583.57 nm



815.23 nm



## → Plan prezentacji

Wstęp

Obrazowanie hiperspektralne

Przetwarzanie HSI: klasyczne algorytmy statystyczne

Przetwarzanie HSI: algorytmy kombinowane, statystyczne + neuronowe

Przetwarzanie HSI: algorytmy w pełni neuronowe

Geneza i podsumowanie

# ► Zabezpieczanie miejsca zdarzenia<sup>abc</sup>

<sup>a</sup>P. Głomb, M. Romaszewski, M. Cholewa, K. Domino „Application of hyperspectral imaging and Machine Learning methods for the detection of gunshot residue patterns” Forensic Science International 290:227-237 (2018)

<sup>b</sup>K. Książek, M. Romaszewski, P. Głomb, B. Grabowski, M. Cholewa „Blood Stain Classification with Hyperspectral Imaging and Deep Neural Networks” Sensors 20(22):6666 (2020)

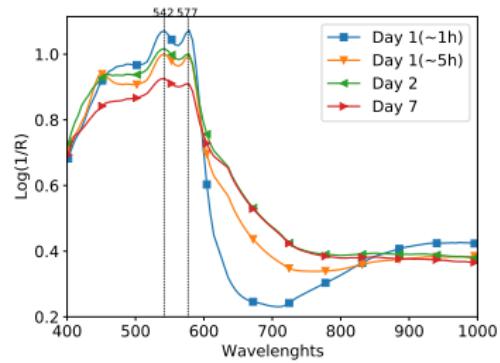
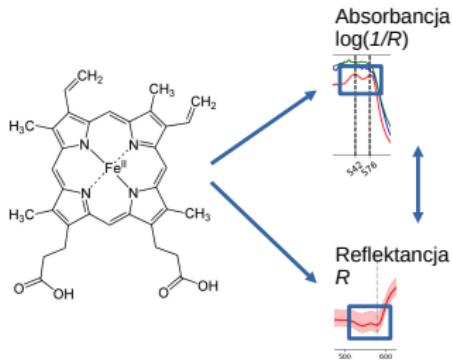
<sup>c</sup>M. Romaszewski, P. Głomb, A. Sochan, M. Cholewa „A dataset for evaluating blood detection in hyperspectral images” Forensic Science International 320:110701 (2021)

**Problem** Detekcja śladów kryminalistycznych krwi i prochu  
(*gunshot residue, GSR*) na miejscu zdarzenia

**Partnerzy** Politechnika Śląska, Szkoła Policji w Pile, CASP  
System Sp.z o.o., Proloc Sp.z o.o. (projekt NCBiR)

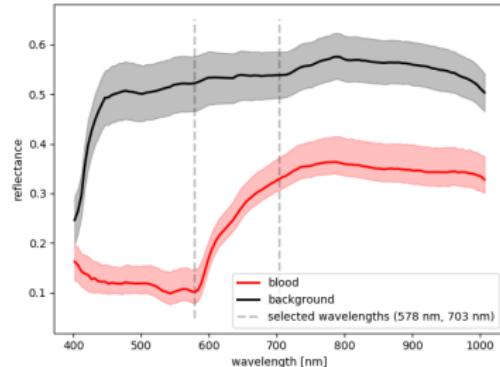


## Wykrywanie wzorców – ślady krwi



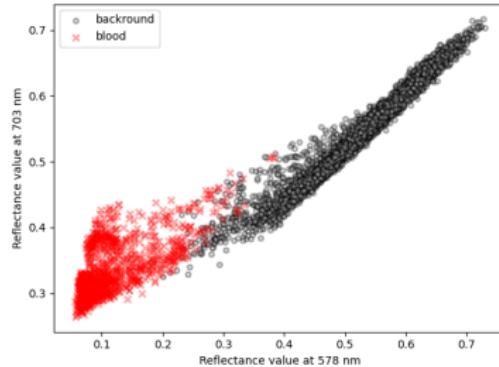
## ❖ Wykrywanie wzorców – wprowadzenie

- ▶ Wzorce celu (ślad krwi) i tła na fragmencie sceny
- ▶ Przykład analizy, dwie wybrane długości światła (z 128) (pojedynczy piksel to  $\mathbf{x} = [x_{578}, x_{703}]$  zamiast  $\mathbf{x} = [x_{376}, x_{381}, x_{386}, \dots, x_{1034}, x_{1040}, x_{1045}]$ )
- ▶ Algorytmy statystyczne (Quadratic Detector, Matched Filter, RX detector)



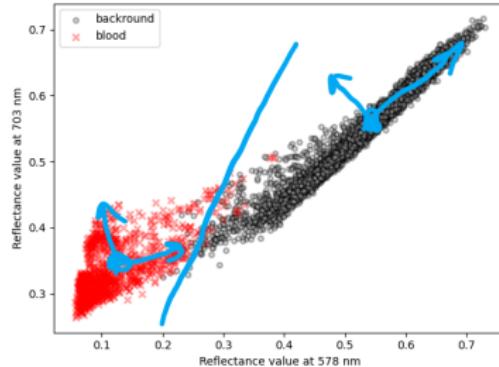
## ► Wykrywanie wzorców – wprowadzenie

- Cel: wskazanie pikseli zawierających poszukiwaną substancję
- Sytuacje:
  1. Znamy szczegóły (=parametry rozkładów) tła i celu
  2. Znamy wzorzec celu
  3. Nie znamy wzorca celu



## ► Wykrywanie wzorców – wprowadzenie

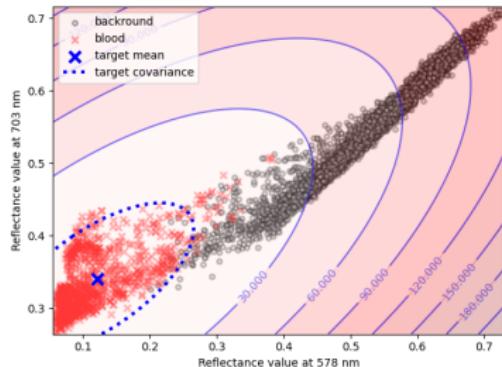
- ▶ Cel: wskazanie pikseli zawierających poszukiwaną substancję
- ▶ Sytuacje:
  1. Znamy szczegóły (=parametry rozkładów) tła i celu



## ► Wykrywanie wzorców – klasyczne algorytmy statystyczne

- Metoda: odległość (Mahalanobisa) od wzorca **celu**, określonego parametrami rozkładu normalnego – średnia  $\mu_1$  i macierz kowariancji  $\Gamma_1$  celu

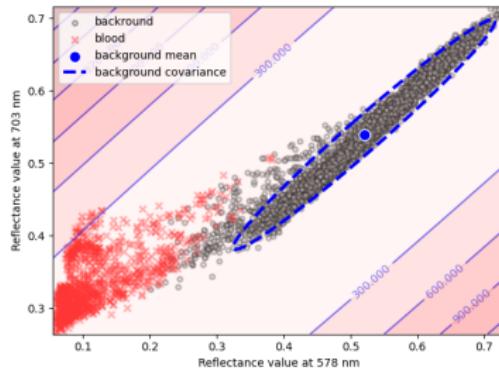
$$D_T(\mathbf{x}, \boldsymbol{\mu}_1, \boldsymbol{\Gamma}_1) = (\mathbf{x} - \boldsymbol{\mu}_1)^T \boldsymbol{\Gamma}_1^{-1} (\mathbf{x} - \boldsymbol{\mu}_1)$$



## ► Wykrywanie wzorców – klasyczne algorytmy statystyczne

- Metoda: odległość (Mahalanobisa) od wzorca **tła**, określonego parametrami rozkładu normalnego – średnia  $\mu_0$  i macierz kowariancji  $\Gamma_0$  tła

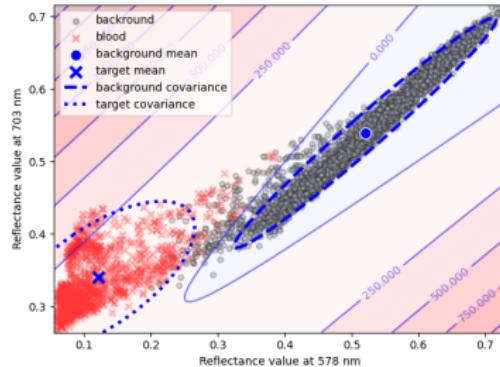
$$D_B(\mathbf{x}, \mu_0, \Gamma_0) = (\mathbf{x} - \mu_0)^T \Gamma_0^{-1} (\mathbf{x} - \mu_0)$$



## ► Wykrywanie wzorców – Quadratic Detector

- Quadratic Detector: różnica odległości (Mahalanobisa) między celem a tłem

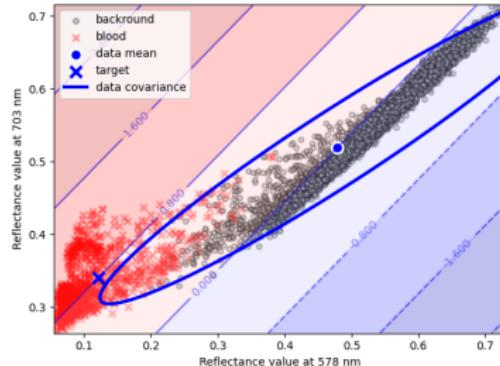
$$D_{QF}(\mathbf{x}, \boldsymbol{\mu}_0, \boldsymbol{\Gamma}_0, \boldsymbol{\mu}_1, \boldsymbol{\Gamma}_1) = D_B(\mathbf{x}, \boldsymbol{\mu}_0, \boldsymbol{\Gamma}_0) - D_T(\mathbf{x}, \boldsymbol{\mu}_1, \boldsymbol{\Gamma}_1)$$



## Wykrywanie wzorców – Matched Filter

- Wymagana znajomość macierzy kowariancji celu –  $\Gamma_1$  – trudna do uzyskania
- Jeżeli znamy sam wzorzec –  $\mu_1$  – wtedy możemy zastosować Matched Filter (wzór uproszczony, bez normalizacji)

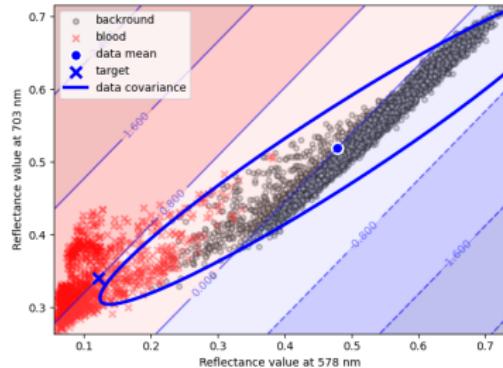
$$D_{\text{MF}}(\mathbf{x}, \boldsymbol{\mu}_0, \boldsymbol{\mu}_1, \boldsymbol{\Gamma}_0) = (\mathbf{x} - \boldsymbol{\mu}_0)^T \boldsymbol{\Gamma}_0^{-1} (\boldsymbol{\mu}_1 - \boldsymbol{\mu}_0)$$



## Wykrywanie wzorców – Matched Filter

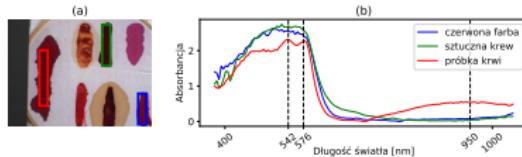
$$D_{\text{MF}}(\mathbf{x}, \boldsymbol{\mu}_0, \boldsymbol{\mu}_1, \boldsymbol{\Gamma}_0) = (\underbrace{\mathbf{x} - \boldsymbol{\mu}_0}_{(1)})^T \underbrace{\boldsymbol{\Gamma}_0^{-1}}_{(2)} (\underbrace{\boldsymbol{\mu}_1 - \boldsymbol{\mu}_0}_{(3)})$$

1. Piksel testowany, skorygowany o średnią tła
2. Przeskalowany przez macierz kowariancji tła (skorygowane różnice między wpływem składowych, ich korelacją)
3. Zrzutowany na wektor różnicy średnia tła – wzorzec celu

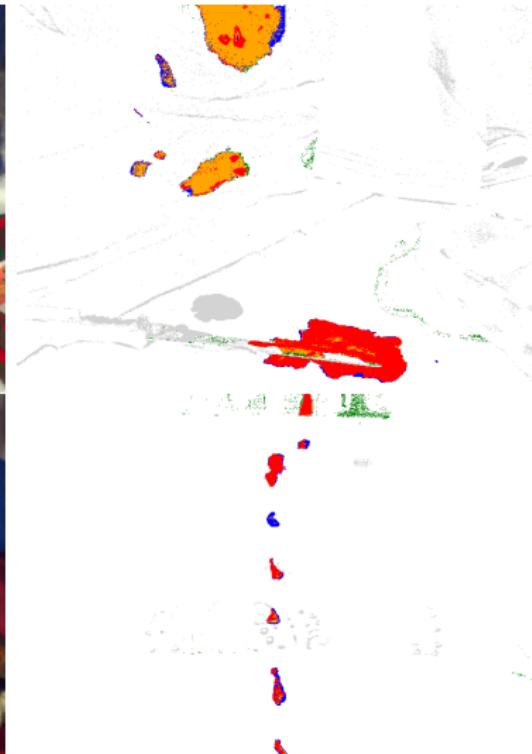


## ► Wykrywanie wzorców – porównanie metod

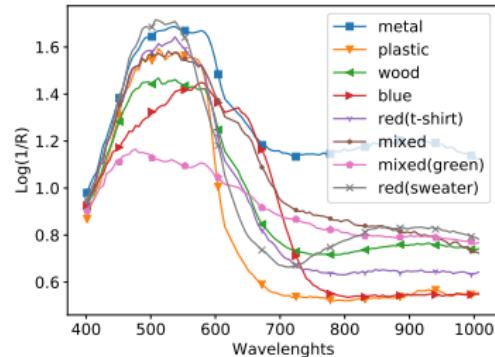
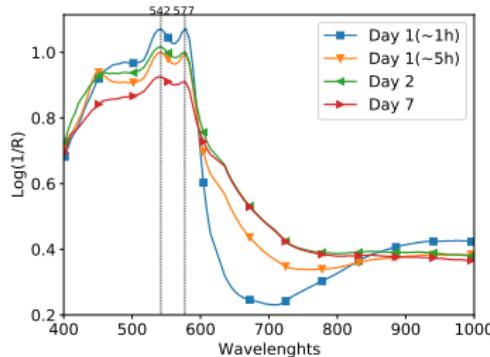
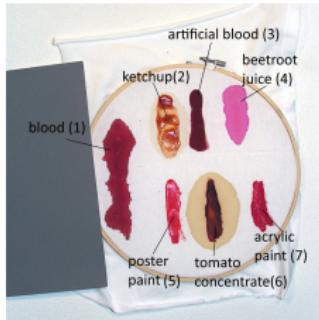
- Cel: wskazanie pikseli zawierających poszukiwaną substancję
- Sytuacje:
  1. Znamy szczegóły (=parametry rozkładów) tła i celu –  
 $D_{QF} = D_B - D_T > T$
  2. Znamy wzorzec celu –  $D_{MF} > T$
  3. Nie znamy wzorca celu –  $D_B > T$
- Uwagi:
  1. Dowolna liczba składowych ( $n$  – wymiarowe wektory)
  2. Rozkład normalny (+) model o znanych cechach, wzory na wyznaczanie parametrów, zrozumiały algorytm, prosty
  3. Rozkład normalny (-) ograniczone możliwości przetwarzania



## → Wykrywanie wzorców – wyniki



## Wykrywanie wzorców – „hiperspektralne” problemy



## → Plan prezentacji

Wstęp

Obrazowanie hiperspektralne

Przetwarzanie HSI: klasyczne algorytmy statystyczne

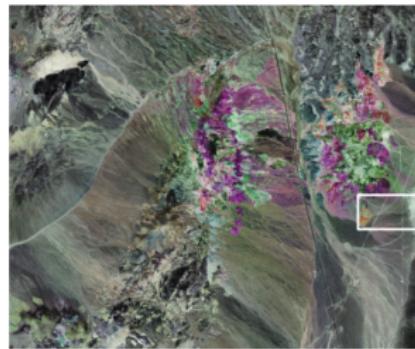
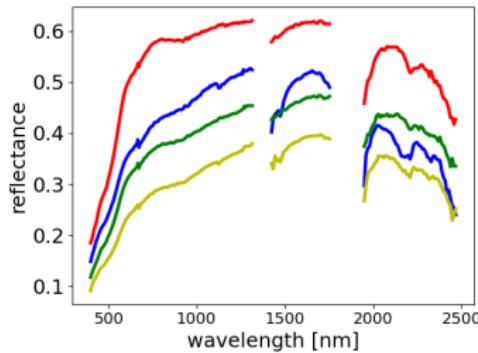
Przetwarzanie HSI: algorytmy kombinowane, statystyczne + neuronowe

Przetwarzanie HSI: algorytmy w pełni neuronowe

Geneza i podsumowanie

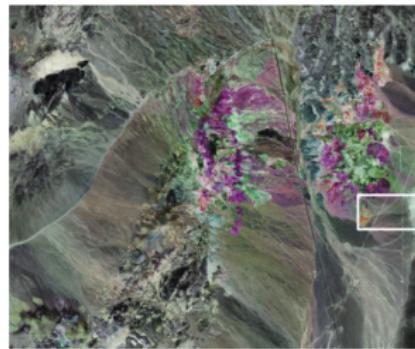
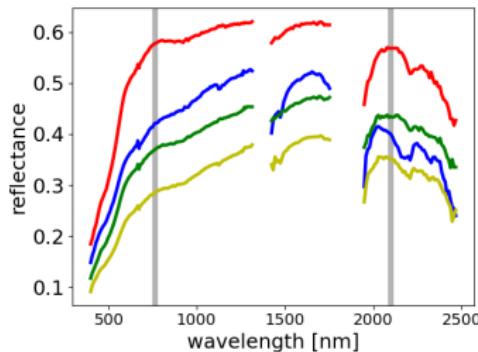
## ► Interludium – problem rozmieszania składowych (ang. unmixing)

- Obszar górniczy Cuprite (USA), kamera AVIRIS



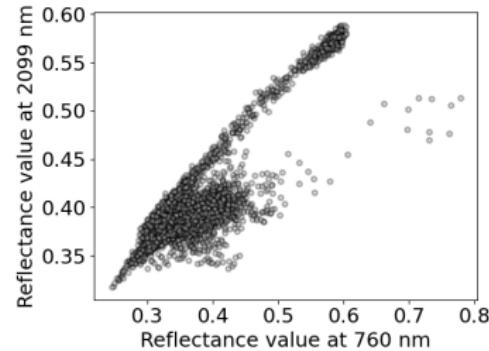
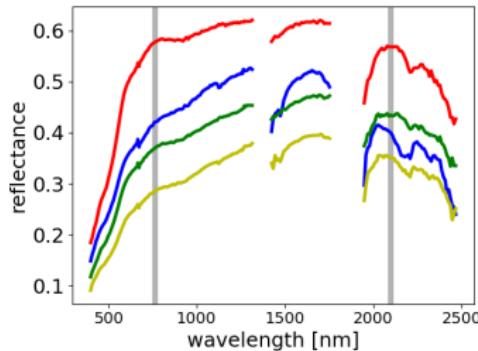
## ► Interludium – problem rozmieszania składowych (ang. unmixing)

- Cuprite – obserwacja dwóch wybranych długości fal ( $\lambda = 760\text{nm}$  i  $\lambda = 2099\text{nm}$ )



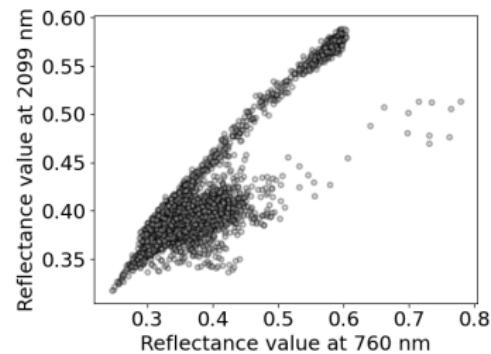
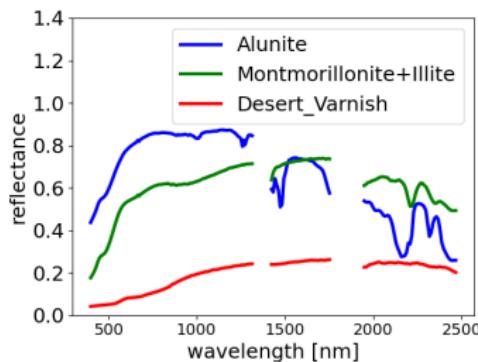
► Interludium – problem rozmieszania składowych (ang. unmixing)

► Cuprite – scatterplot hiperspektralnych pikseli



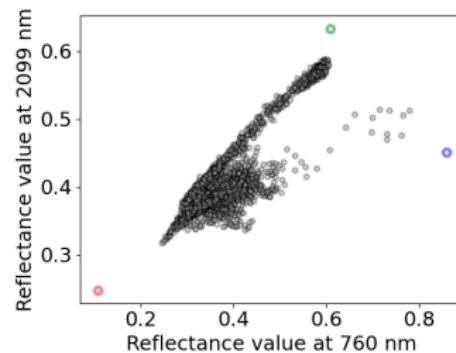
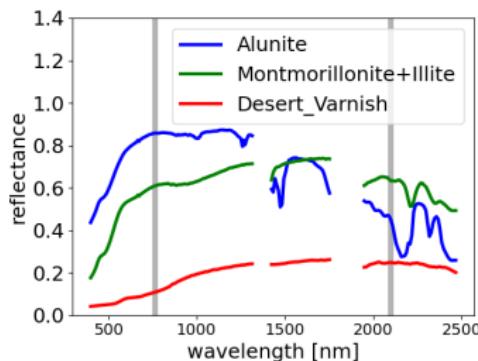
## ► Interludium – problem rozmieszania składowych (ang. unmixing)

- Cuprite – znamy minerały / substancje występujące w scenie



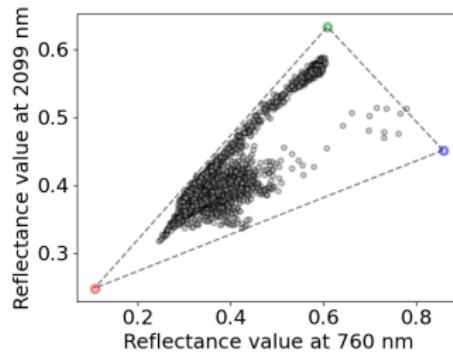
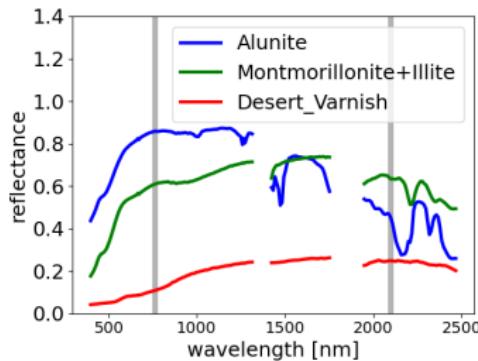
## ► Interludium – problem rozmieszania składowych (ang. unmixing)

### ► Cuprite – składowe sceny (ang. endmembers)



## ► Interludium – problem rozmieszania składowych (ang. unmixing)

- Cuprite – piksel można wyrazić jako sumę składowych  
 $\hat{x} \approx a_1 \times \text{Alunite} + a_2 \times \text{Monm.Illite} + a_3 \times \text{Desert V.}$

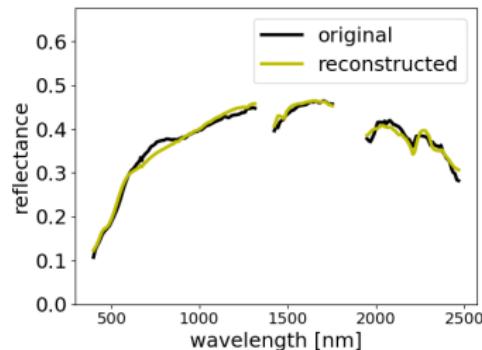
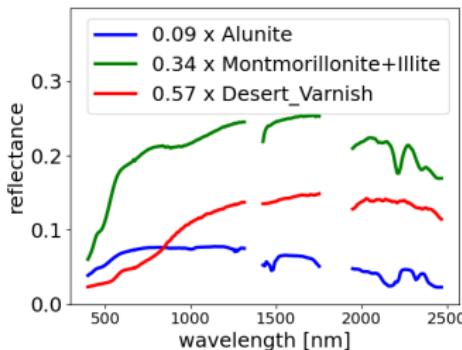


## ► Interludium – problem rozmieszania składowych (ang. unmixing)

- hiperspektralny piksel o wymiarze  $b$  (np.  $b = 187$ )

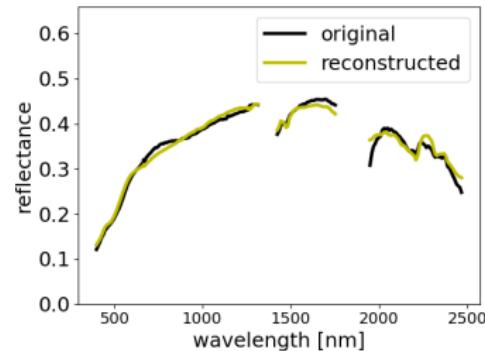
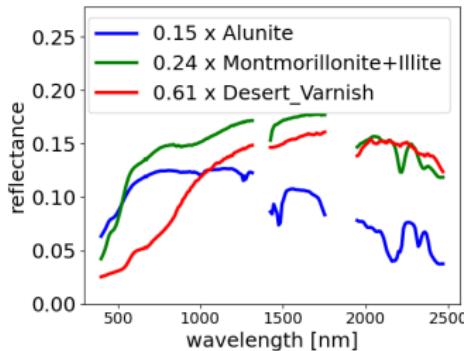
$\mathbf{x} = [x_1, \dots, x_B]$  modelujemy jako rekonstrukcję  $k$  składowych (np.  $k = 3$ ) z dodatkiem szumu

$$\mathbf{x} = \sum_{j=1}^k a_j \cdot \mathbf{m}_j + \mathbf{n},$$



## ► Interludium – problem rozmieszania składowych (ang. unmixing)

- + Model sceny zgodny z rzeczywistością
- + Kompresja
- + Identyfikacja substancji
- Trudność wyznaczenia parametrów (składowych)

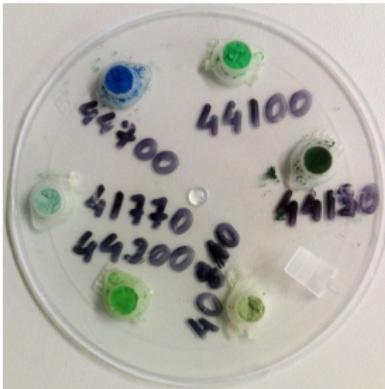


## → Identyfikacja pigmentów<sup>a</sup>

<sup>a</sup>B. Grabowski, W. Masarczyk, P. Głomb, A. Mendys „Automatic pigment identification from hyperspectral data” Journal of Cultural Heritage 31:1-12 (2018)

**Problem** Klasyfikacja pigmentów użytych do malowania obrazów w kolekcji muzealnej

**Partner** Laboratorium Analiz i Nieniszczących Badań Obiektów Zabytkowych (LANBOZ), Muzeum Narodowe w Krakowie



## → Identyfikacja pigmentów – problem

- ▶ Badania obrazów z wykorzystaniem różnych metod
- ▶ Różne pigmente zielone na bazie miedzi → obrazowanie hiperspektralne
- ▶ Konieczność identyfikacji pigmentu dla doboru materiałów do konserwacji
- ▶ Widmo zmieszane: pigment, spoiwo, podkład, tło



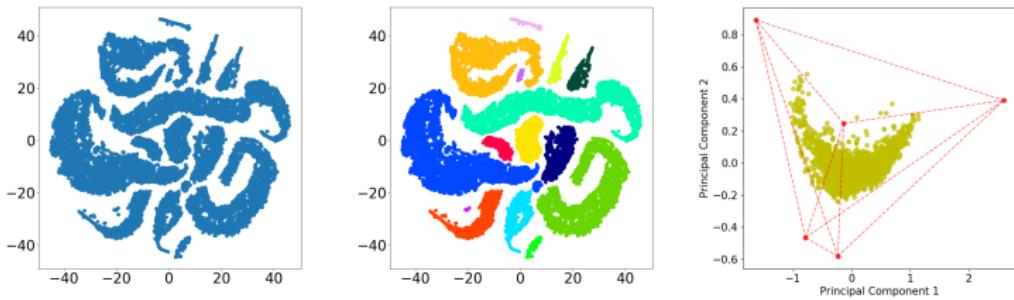
## → Identyfikacja pigmentów – założenia

- ▶ Mamy bazę pigmentów, ale nie spoiwa i tła (za dużo kombinacji) → oszacowanie z danych
- ▶ Duża liczba składowych → oszacowanie niedokładne, błędy
- ▶ Oszacowanie z fragmentu z jednym pigmentem → oszacowanie dokładne, ale ...
- ▶ ... potrzebujemy znać pigmente, żeby wyznaczyć fragment, i jednocześnie znać fragment, żeby wyznaczyć pigmente → Paragraf 22



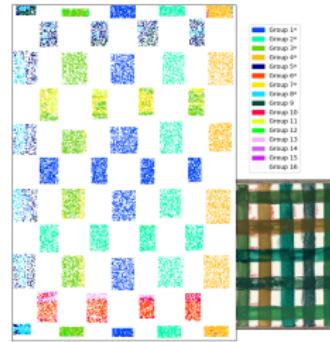
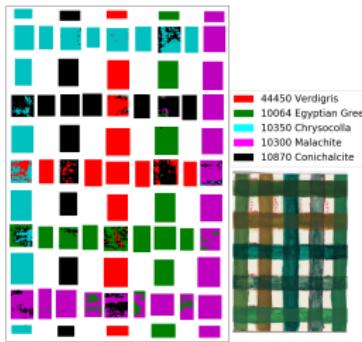
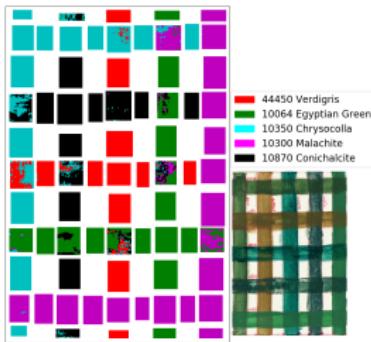
## → Identyfikacja pigmentów – algorytm

1. Redukcja wymiarowości (t-SNE) + grupowanie (DBSCAN)
2. Identyfikacja składowych (SISAL)
3. Klasyfikacja (sieć neuronowa)



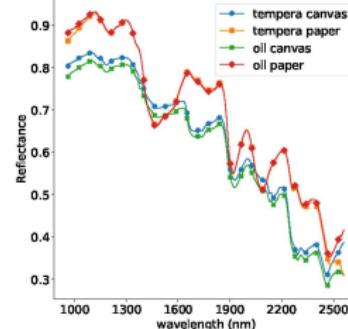
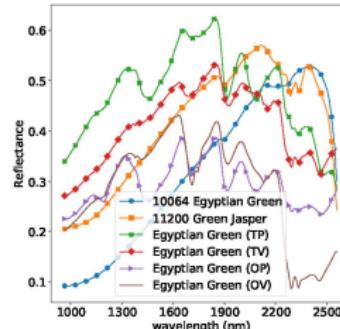
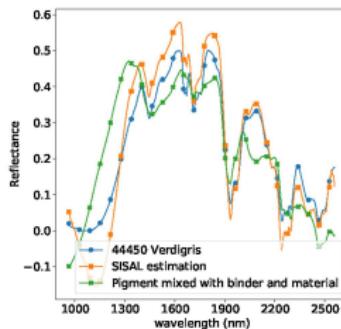
## → Identyfikacja pigmentów – eksperyment

1. Grupowanie wyznacza duże, jednolite grupy
2. Identyfikacja składowych wyznacza ich składowe i wskazuje które pigmente były użyte
3. Klasyfikacja oznacza niejednoznaczne przypadki



## → Identyfikacja pigmentów – eksperyment

- ▶ Przykład łączenia algorytmów uczenia maszynowego w ramach jednego algorytmu
- + Rozwiążanie złożonego problemu
- + Zrozumiała struktura algorytmu (→ weryfikacja)
- Konieczna wiedza eksperta w celu dobrania metod i parametrów



## → Plan prezentacji

Wstęp

Obrazowanie hiperspektralne

Przetwarzanie HSI: klasyczne algorytmy statystyczne

Przetwarzanie HSI: algorytmy kombinowane, statystyczne + neuronowe

Przetwarzanie HSI: algorytmy w pełni neuronowe

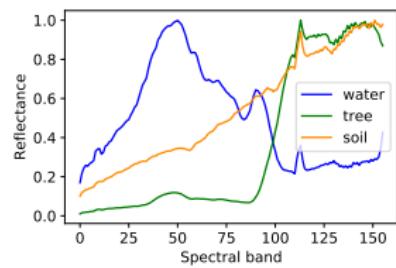
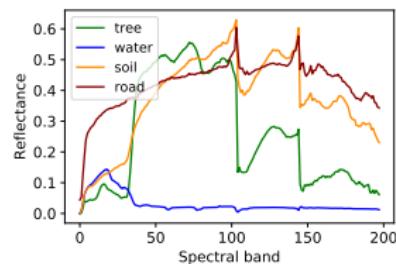
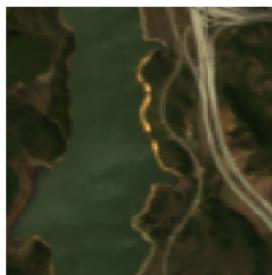
Geneza i podsumowanie



# Identyfikacja składowych<sup>a</sup>

<sup>a</sup>K. Książek, P. Głomb, M.Romaszewski, M. Cholewa, B.Grabowski „Stable training of autoencoders for hyperspectral unmixing”, zgłoszony na ICCV 2021

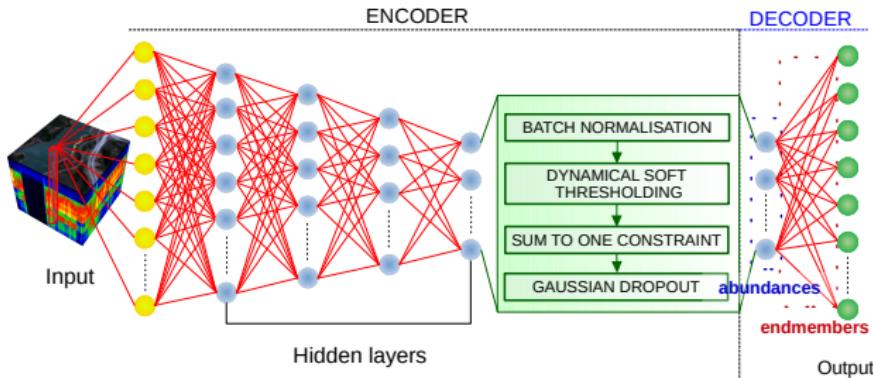
Problem Identyfikacja składowych – podejście w pełni neuronowe



## Autoenkodery

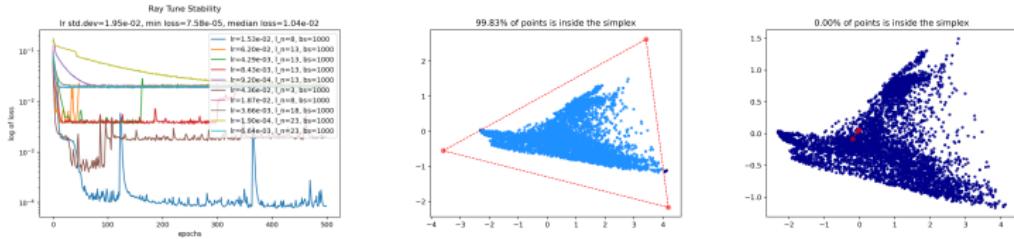
- ▶ Autoenkoder: część kodująca i dekodująca, „kod” danych
- ▶ B. Palsson et al, „Hyperspectral Unmixing Using a Neural Network Autoencoder” IEEE Access 6:25646 - 25656
- ▶ Dekoder realizuje

$$\hat{\mathbf{x}} = \sum_{j=1}^k a_j \mathbf{m}_j$$



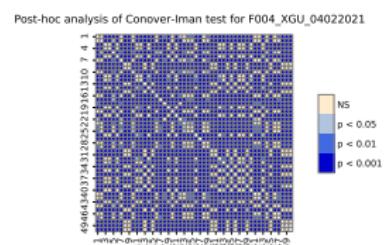
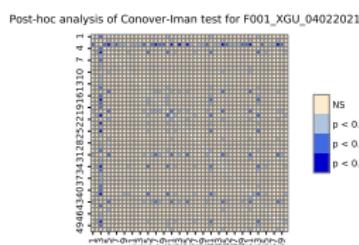
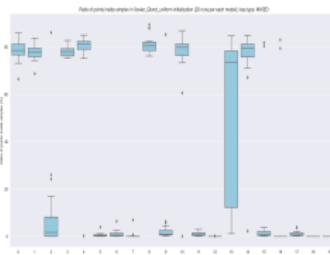
## → Wykorzystanie autoenkodera do problemu identyfikacji składowych

- ▶ Potencjalne rozwiązanie problemu doboru algorytmów
- ▶ Problem: doboru architektury → oryginalna (jak w artykule B. Palsson i uproszczona)
- ▶ Problem: doboru hiperparametrów → RayTune
- ▶ Wszystkie składniki gotowe, eksperyment działa, architektura uproszczona wstępnie daje bardziej obiecujące wyniki, ale ...
- ▶ ... pojawia się problem z inicjalizacją wag



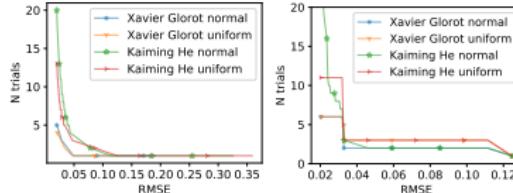
## ► Problem inicjalizacji autoenkodera

- Parametry metody
  - Regresja liniowa  $y = ax + b \rightarrow (a, b)$
  - Autoenkoder → wagi
- Uczenie: (1) losowanie (inicjalizacja) wag (2) trening
- Losowe przypadki kiedy wagi prowadzą do negatywnego rezultatu



## ► Problem inicjalizacji autoenkodera

- Niezależnie od przyjętej architektury, zbioru danych, funkcji loss, zbioru hiperparametrów, miary błędów, wyboru metody inicjalizacji ... niezależnie od parametrów, którymi możemy sterować  
(weryfikacja na 100 000 eksperymentach uczenia)
- Paragraf 22: potrzeba dobrych inicjalizacji żeby wyznaczyć wartości hiperparametrów; potrzeba wyznaczonych wartości hiperparametrów żeby rozróżnić dobre/złe inicjalizacje
- (Tymczasowe) rozwiązanie: wyznaczenie liczby losowań potrzebnych aby z określonym prawdopodobieństwem (np. 95%) uzyskać przynajmniej jedną dobrą inicjalizację
- Problem badamy :) – analiza gradientów w sieci



# → Plan prezentacji

**Wstęp**

**Obrazowanie hiperspektralne**

**Przetwarzanie HSI: klasyczne algorytmy statystyczne**

**Przetwarzanie HSI: algorytmy kombinowane, statystyczne + neuronowe**

**Przetwarzanie HSI: algorytmy w pełni neuronowe**

**Geneza i podsumowanie**

## ➤ Geneza tematu obrazowania HSI w IITiS

- ▶ Projekt zlecony: dobór algorytmów stabilizacji obrazu i śledzenia celów dla operatora UAV
- ▶ Prototyp do demonstracji (2010-2011, dla Flytronic sp. z o.o.)
- ▶ Wyróżnienie Ministra Spraw Wewnętrznych (MSPO Kielce 2010)
- ▶ Częściowo zaimplementowane w WB Electronic FlyEye



## → Badania hiperspektralne w IITiS PAN

1. Trzy projekty (NCN, NCBiR, Diamentowy Grant) + European JPICH Digital Heritage
2. 6 osób zaangażowanych w temat badawczy +4 współpracujące
3. 13 publikacji (7 JCR, 1 rozdział w monografii Elsevier), +2 w przygotowaniu.
4. Rozprawa doktorska (wyróżnienie), habilitacja, dwa rozpoczęte doktoraty
5. 3 zastosowania rozpoznane, 2 inne w trakcie badań
6. Praktyczne doświadczenie, wyposażenie laboratorium (kamera SOC-710VP), obiecujące kierunki badawcze



## ► Diagnostyka ran oparzeniowych

**Problem** Wspomaganie diagnostyki medycznej ran oparzeniowych i innych

**Partner** Centrum Leczenia Oparzeń w Siemianowicach Śląskich



## → Podsumowanie

1. Obrazowanie hiperspektralne – drogie, trudne, daje duże możliwości
2. Problem doboru algorytmów uczących dla obrazowania hiperspektralnego
  - 2.1 Możliwości obrazowania, różnorodność zastosowań
  - 2.2 Dużo danych, utrudnione pozyskanie etykiet
  - 2.3 Różnice w stosunku do klasycznego obrazowania
3. Planowane prace (główne kierunki)
  - 3.1 Analiza hiperspektralna śladów krwi oraz obrazów ran oparzeniowych
  - 3.2 Metody nienadzorowane w parametryzacji sieci głębokiego uczenia dla obrazowania hiperspektralnego



→ Dziękuję za uwagę!

Pytania?